UNIVERSIDAD DE LA FRONTERA
FACULTAD DE INGENIERÍA Y CIENCIAS
DEPARTAMENTO DE [COMPLETAR: Departamento del Profesor Guía]

(logo UFRO — COMPLETAR: insertar imagen institucional)

«ReqCouncil: sistema multi-agente basado en modelos de lenguaje para la derivación asistida y trazable de requisitos de software a partir de transcripciones de reuniones de elicitación»

ACTIVIDAD DE TITULACIÓN, MODALIDAD PROYECTO DE INTEGRACIÓN DE INFORMÁTICA

(nota: no es «Proyecto de Titulación» ni «Práctica Profesional Controlada» en sentido estricto — ajustar la línea anterior a la nomenclatura institucional exacta si corresponde)

Profesor Guía: Jorge Díaz Villegas
Profesor Co-guía: no aplica

[COMPLETAR: NOMBRE COMPLETO DEL ESTUDIANTE]
2026

«ReqCouncil: sistema multi-agente basado en modelos de lenguaje para la derivación asistida y trazable de requisitos de software a partir de transcripciones de reuniones de elicitación»

[COMPLETAR: NOMBRE COMPLETO DEL ESTUDIANTE]

COMISIÓN EVALUADORA

Jorge Díaz Villegas — Profesor Guía

Académico evaluador	**Académico evaluador**
COMPLETAR: nombre	COMPLETAR: nombre

Calificación informe escrito: _____

Calificación presentación oral: _____

Calificación final: _____

RESUMEN EJECUTIVO

La ingeniería de requisitos depende mayoritariamente de reuniones y entrevistas de elicitación, cuya traducción manual a requisitos formales es propensa a omisiones y presenta una variabilidad extrema entre analistas: sobre una misma conversación de stakeholders documentada en la literatura, tres expertos derivaron individualmente 103, 47 y 34 requisitos, mientras que su consenso Delphi final contenía solo 27. Los enfoques automáticos existentes reproducen el problema en espejo: los modelos de lenguaje de una sola pasada extraen bien los requisitos explícitos, pero omiten sistemáticamente los no funcionales e implícitos, o sobre-generan (una herramienta de referencia produjo 134 requisitos para esa misma conversación).

Para abordar este problema se desarrolló **ReqCouncil**, un sistema multi-agente basado en el modelo de lenguaje DeepSeek-V4-Flash (servido por SiliconFlow) y orquestado con LangGraph, que recibe la transcripción de una reunión de elicitación y produce un borrador de requisitos calibrado y trazable. En lugar de una pasada única, un *council* de nueve personas sintéticas — seis analistas por categoría (funcional, datos, NFR, seguridad y cumplimiento, UX, integraciones) y tres críticos adversariales (Gap Hunter, Conflict Detector, Evidence Skeptic)— delibera en rondas acotadas sobre un blackboard compartido, con un protocolo de consenso (SUPPORT/REVISE/DROP) y un criterio de convergencia explícito, hasta colapsar en un conjunto de requisitos «con el que todos pueden vivir». Cada requisito aceptado queda anclado a los fragmentos exactos de la transcripción que lo justifican, y un checkpoint humano no-salteable (ordenado peor-primero) cierra el ciclo antes de emitir el documento final.

El desarrollo fue guiado por evaluación (*eval-driven*) contra cuatro corpora públicos con verdad fundamental: Inter2US (37 historias golden y 760 pares chunk-historia anotados por humanos), WEPGCOMP y +Lugar (transcripciones industriales reales en portugués, con oráculos **medidos** de 46 y 34 requisitos), ReqElicitBench (101 escenarios con requisitos implícitos ocultos) y RECOVER (consenso de expertos). El arnés de evaluación mide fidelidad, cobertura, recall de requisitos críticos y un índice de calibración de cardinalidad, con umbrales que bloquean la integración de cambios (fidelidad ≥ 0,7; recall crítico ≥ 0,9). Ejecutada la evaluación completa (E0–E4, 2026-07-06): el arnés queda hermético y en verde (8 gates green · 3 waived con razón medida · 2 n/a · exit 0, 142 tests), y la ablación de 12 celdas (3 corpus × 4 condiciones) muestra que el council completo **no domina ningún eje validado contra el oráculo externo** (fidelidad, recall, precisión, NFR) frente a un single-pass con prompt fuerte que cuesta 8,8×–12,0× menos tokens — su única ventaja consistente es la cobertura del transcript, no el acierto contra el oráculo.

Se concluye que estructurar la derivación de requisitos como deliberación multi-agente con evidencia obligatoria y evaluación bloqueante convierte un proceso artesanal y no auditable en

un proceso medible, trazable y reproducible, manteniendo al ingeniero humano como autoridad final de decisión — pero que, medido de punta a punta, **el costo de la deliberación completa no se justifica como arquitectura de extracción pura**: el valor real que queda en pie es la capa de verificación/ anclaje (juez calibrado, agnóstica al número de críticos) y el checkpoint humano estructuralmente no-salteable, no la cardinalidad de la deliberación en sí.

(Extensión: ~380 palabras; máximo 1½ páginas — guía §2)

ÍNDICE DE CONTENIDOS

1.1 Planteamiento del problema 1
1.2 Justificación y pertinencia 2
1.3 Objetivo general 2
1.4 Objetivos específicos 2
1.5 Alcance y limitaciones iniciales 3
2.1 Fundamentos teóricos y técnicos 5
2.2 Estado del arte y comparación de alternativas 6
2.3 Justificación de herramientas y tecnologías 8
3.1 Enfoque metodológico 10
3.2 Planificación, hitos y gestión de riesgos 10
3.3 Stakeholders, requisitos y criterios de aceptación 16
3.4 Requisitos funcionales y no funcionales 16
3.5 Diseño de la solución y decisiones clave 18
3.6 Implementación e integración 24
3.7 Reproducibilidad, control de versiones y autoría 25
3.8 Seguimiento, control de cambios y definición de terminado 25
4.1 Entregable funcional y alcance logrado 28
4.2 Cumplimiento de objetivos 28
4.3 Pruebas, métricas y rigor de evaluación 30
4.4 Comparación con línea base 33
4.5 Análisis crítico, limitaciones y amenazas a la validez 36
5.1 Síntesis de logros 40
5.2 Reflexión crítica y aprendizajes 40
5.3 Trabajo futuro priorizado 41
Nomenclatura 43
Bibliografía 43

ÍNDICE DE TABLAS

1 Tabla 2.1. Comparación de enfoques para derivar requisitos desde conversaciones. 6
2 Tabla 2.2. Frameworks de orquestación multi-agente considerados. 7
3 Tabla 2.3. Tecnología → requisito que la motiva → por qué sobre las alternativas. 8
4 Tabla 3.1. Hitos y entregables. 10
5 Tabla 3.2. Riesgos identificados y mitigación. 14
6 Tabla 3.3. Requisitos del sistema ReqCouncil. 16
7 Tabla 4.1. Trazabilidad objetivos específicos → evidencia. 28
8 Tabla 4.2. Resultados E0 (calibración del juez). 30
9 Tabla 4.3. Resultados E1 (corpus primario IFA) y E2 (industria real). 31
10 Tabla 4.4. Resultados E3 (escala; N=20 escenarios ReqElicitBench estratificados, seed=7). . 31
11 33
12 43

ÍNDICE DE FIGURAS

1 Figura 3.1. Arquitectura general de ReqCouncil (elaboración propia). 20
2 Figura 3.2. Loop de deliberación del Council (elaboración propia). 22
3 Figura 3.3. Modelo de datos del almacén de trazabilidad (elaboración propia). 23

CAPÍTULO 1
INTRODUCCIÓN

1.1 Planteamiento del problema

En la práctica industrial, la mayor parte de los requisitos de software se descubre en instancias conversacionales: entrevistas semiestructuradas, talleres de descubrimiento y reuniones de análisis de brechas. Estudios empíricos sobre transcripciones reales muestran que solo entre el 8,6% y el 12% del tiempo de conversación corresponde a requisitos formulados explícitamente; el resto es descripción de procesos actuales y futuros, exploración y contexto, del cual el analista debe *inferir* la gran mayoría de los requisitos (informe de análisis propio sobre la literatura, `docs/reference/informe_que_explica_utilidad.md`; [FALTA DATO: cita primaria del estudio Fit-Gap]).

La transición desde esa conversación —ambigua, redundante, con conocimiento tácito— hacia un artefacto formal (historias de usuario, especificación de requisitos) depende hoy de notas manuales y de la retentiva del analista. La evidencia disponible en los datos de este proyecto muestra dos consecuencias concretas y medibles:

1. **Variabilidad e inconsistencia entre analistas.** En el corpus público del enfoque RECOVER, tres expertos que analizaron la misma conversación produjeron 103, 47 y 34 requisitos respectivamente; su consenso Delphi final contenía 27. La cardinalidad del resultado depende más de quién analiza que de lo que se dijo (fuente: `datasets/recover/requirements_lists/`).
2. **Los enfoques automáticos actuales fallan en direcciones opuestas.** Sobre esa misma conversación, un LLM de una sola pasada produjo 30 requisitos con omisiones conocidas, y la herramienta RECOVER produjo 134 (sobre-generación ~5× respecto del consenso experto). El estudio WER 2025 sobre los sistemas industriales WEPGCOMP y +Lugar midió además que los LLM identifican bien los requisitos funcionales explícitos pero fallan sustancialmente en los no funcionales, confundiéndolos u omitiéndolos.

Los actores afectados son los analistas de requisitos y los equipos de desarrollo que heredan especificaciones incompletas o infladas: retrabajo por malinterpretación de alcance, defectos de origen temprano (los más caros de corregir) y pérdida del vínculo entre el requisito y la voz real del cliente.

Delimitación. Este proyecto aborda exclusivamente la capa agéntica del problema: desde una transcripción ya existente (con hablantes etiquetados) hasta un borrador de requisitos revisado por un humano. El reconocimiento de voz, la diarización y el procesamiento de audio quedan fuera del alcance, por ser tecnología madura y separable. También queda fuera la negociación posterior de requisitos con stakeholders.

Restricciones conocidas al inicio: los corpora públicos con verdad fundamental están en inglés y portugués (no en español); las entrevistas de los corpora académicos son parcialmente simuladas;

el presupuesto de cómputo obliga a acotar las rondas de deliberación y el tamaño de la evaluación a gran escala.

1.2 Justificación y pertinencia

Resolver este problema importa porque la elicitación es la fase del ciclo de vida donde los errores son más baratos de prevenir y más caros de heredar, y porque el insumo (transcripciones) ya existe de forma masiva: las organizaciones graban sus reuniones, pero ese material no se explota sistemáticamente como evidencia de requisitos. La pertinencia del momento es doble. Primero, por primera vez existen corpora públicos que vinculan transcripciones reales con los requisitos que ingenieros humanos derivaron de ellas (Inter2US, WEPGCOMP/+Lugar, ReqElicitBench, RECOVER), lo que permite desarrollar un sistema de este tipo de forma *data-driven*, midiendo contra verdad fundamental en lugar de iterar a ciegas. Segundo, la literatura reciente muestra que los enfoques de una sola pasada ya se probaron y sus modos de falla están caracterizados (omisión de NFR, descalibración de cardinalidad); lo que no existe como pieza disponible es un sistema que estructure la derivación como *deliberación con consenso* —el mecanismo que en los datos de RECOVER demostró colapsar la variabilidad humana— con trazabilidad a la evidencia y evaluación bloqueante. Esa es la brecha que este proyecto cubre.

1.3 Objetivo general

Desarrollar un sistema multi-agente basado en modelos de lenguaje que derive, mediante deliberación estructurada y con trazabilidad a la evidencia, un conjunto calibrado de requisitos de software a partir de transcripciones de reuniones de elicitación, evaluado contra corpora públicos con verdad fundamental.

1.4 Objetivos específicos

- **OE1.** Diseñar e implementar la ingesta y anclaje de transcripciones: segmentación en ventanas de 3 turnos (stride 1) con identificadores estables direccionados por contenido.
- **OE2.** Diseñar e implementar el protocolo de deliberación multi-persona (council de 6 analistas de categoría y 3 críticos adversariales) con protocolo de consenso y criterio de convergencia explícito, sobre DeepSeek-V4-Flash (SiliconFlow) y LangGraph.
- **OE3.** Implementar la trazabilidad requisito ↔ evidencia ↔ decisión en un almacén relacional y el checkpoint humano no-salteable con paquete de revisión ordenado peor-primero.
- **OE4.** Construir el arnés de evaluación sobre cuatro corpora golden públicos, con métricas de fidelidad, cobertura, recall de requisitos críticos y calibración de cardinalidad, y umbrales bloqueantes de integración.

- **OE5.** Evaluar el sistema contra líneas base de una sola pasada y una ablación sin críticos, reportando calidad por métrica y costo por token.

(Trazabilidad OE→evidencia: tabla en el Capítulo 4, sección 4.2.)

1.5 Alcance y limitaciones iniciales

Incluye: parser y chunking de transcripciones; council completo (analistas, críticos, consenso, convergencia); síntesis de historias de usuario (plantilla Connextra) y NFR medibles; almacén de trazabilidad; checkpoint humano; arnés de evaluación E0–E4 con gates. **No incluye:** ASR/diarización; OCR de material visual de reuniones; atribución por ablación de contexto; optimización automática de prompts; interfaz web de revisión (la revisión es por CLI). **Supuestos:** la transcripción llega con hablantes etiquetados y calidad razonable; el API del modelo está disponible durante las corridas; los corpora públicos son redistribuibles para investigación dentro del repositorio del proyecto.

CAPÍTULO 2
ANTECEDENTES GENERALES

2.1 Fundamentos teóricos y técnicos

Elicitación de requisitos e ingeniería de requisitos conversacional. La elicitación es la actividad de descubrir necesidades y restricciones de stakeholders; en la práctica se realiza predominantemente por medios conversacionales (entrevistas, talleres). El campo NLP4RE (procesamiento de lenguaje natural aplicado a ingeniería de requisitos) estudia cómo derivar artefactos formales desde ese material. Este concepto es central porque el sistema desarrollado opera exactamente en esa transición: transcripción → requisitos. La calidad formal del artefacto resultante se define aquí según ISO/IEC/IEEE 29148 (requisito bien formado: completo, no ambiguo, verificable, singular, factible, trazable, consistente) y la taxonomía de atributos de calidad de ISO/IEC 25010 — ambas normas se usan como rúbrica del Synthesizer y del arnés de evaluación.

Historias de usuario y plantilla Connextra. La historia de usuario («Como [rol], quiero [acción], para [beneficio]») es el formato estándar ágil de captura de requisitos funcionales. Se adopta como formato de salida porque los corpora golden del proyecto (Inter2US, ReqElicitBench) expresan su verdad fundamental en ese formato, lo que hace la evaluación directamente comparable.

Trazabilidad pre-especificación. A diferencia de la trazabilidad clásica (requisito→código→ prueba), la trazabilidad *pre-RS* vincula el requisito hacia atrás con la evidencia conversacional que lo originó. En este proyecto cada requisito aceptado porta *anclas* (identificadores de fragmentos de transcripción); la métrica de fidelidad del Capítulo 4 es la operacionalización cuantitativa de este concepto.

Modelos de lenguaje grandes y sistemas multi-agente. Un LLM de una sola pasada puede extraer requisitos explícitos con precisión comparable a un analista junior, pero falla en lo implícito y lo no funcional (evidencia en 2.2). Los esquemas de debate multi-agente (MAD) instancian varias personas sintéticas que argumentan y un mecanismo que adjudica, reduciendo sesgos individuales a costo de mayor consumo de tokens. Este concepto fundamenta la decisión arquitectónica central del proyecto: el council deliberativo. Se usa aquí con dos salvaguardas propias: anonimato de autoría entre agentes (anti-sicofancia) y prohibición de citar texto del debate como evidencia (solo la transcripción ancla; anti-«lavado de alucinaciones»).

Orquestación con grafos de estado y checkpoint humano. LangGraph modela el sistema multi--agente como grafo de estado tipado que compila y es verificable estructuralmente antes de ejecutar; los checkpoints durables permiten reanudar corridas y el mecanismo `interrupt()` implementa un punto de control humano que, por construcción del grafo (alcanzabilidad), no puede ser evitado. Estos conceptos sustentan los requisitos RNF4 (durabilidad) y RF7 (checkpoint no-salteable).

2.2 Estado del arte y comparación de alternativas

Panorama. Cuatro líneas de trabajo recientes convergen en el problema transcripción→requisitos: (a) **RECOVER** (Voria, Casillo, Gravino, Catolino y Palomba, 2024. *RECOVER: Toward Requirements Generation from Stakeholders' Conversations*, arXiv:2411.19552) genera requisitos automáticamente desde conversaciones de stakeholders; su apéndice público aporta el caso de consenso experto usado en este proyecto. (b) **Inter2US** (Dente, Dalpiaz y Papotti, 2025. *Automated Alignment between Elicitation Interviews and Requirements*, arXiv:2510.08622; Zenodo DOI 10.5281/zenodo.20596692) formaliza la alineación entrevista ↔ historia y publica la anotación humana (760 pares) que permite calibrar jueces automáticos; define las métricas de *correctness* (fidelidad) y *coverage* adoptadas aquí. (c) **ReqElicitGym/ReqElicitBench** (Jin, Jin, Fang, Li, Yang, He y Chen, 2026. arXiv:2602.18306) evalúa competencia de entrevista de agentes LLM sobre 101 escenarios con requisitos implícitos ocultos; sus registros de conversación con DeepSeek constituyen una línea base publicada. (d) el **estudio WER 2025 sobre WEPGCOMP y +Lugar** (Almeida, Copque, Oliveira, Arouca et al., 2025. *From Elicitation Interviews to Software Requirements: Evaluating LLM Performance in Requirement Generation*, WER 2025, DOI 10.29327/1588952.28-12; Zenodo DOI 10.5281/zenodo.15080374) mide generación de requisitos desde transcripciones industriales reales (en portugués) y caracteriza la debilidad sistemática de los LLM en requisitos no funcionales — debilidad que este proyecto **reproduce y cuantifica** en E2 (Cap. 4, Tabla 4.3: recall NFR crítico 0,50 en WEPGCOMP y 0,00 en +Lugar, ningún arm de la ablación E4 alcanza 0,9). Trabajos complementarios: REConSum (resumen extractivo de conversaciones de elicitación, Universidad de Utrecht) y OntoAgent (inducción de ontologías de experiencia; mejora reportada de +33% en tasa de elicitación de implícitos sobre LLMs base) [FALTA DATO: citas completas — residual de biblioteca, ver 06-bibliografia-nomenclatura.md].

Criterio	Analista manual	LLM single-pass	Pipeline extractivo (RECOVER)	**Council deliberativo (este proyecto)**
Recall de explícitos	alto	alto	alto	alto
Recall de NFR/ implícitos	depende del experto	**bajo (medido)**	medio	objetivo del diseño (gate ≥ 0,9)
Calibración de cardinalidad	34–103 para un mismo input	~1× pero con omisiones	**~5× (sobre-generación)**	gobernada por consenso + banda CCI
Trazabilidad a la evidencia	notas informales	no nativa	parcial	**nativa (anclas obligatorias)**

Criterio	Analista manual	LLM single-pass	Pipeline extractivo (RECOVER)	**Council deliberativo (este proyecto)**
Auditabilidad del proceso	no	no	parcial	completa (log de deliberación)
Costo por documento	horas-persona	mínimo	bajo	medio (×2–4 tokens vs single-pass)

Tabla 2.1. Comparación de enfoques para derivar requisitos desde conversaciones.

Conclusión de la comparación. Ningún enfoque existente combina recall de implícitos, cardinalidad calibrada y trazabilidad auditable; el costo adicional del enfoque deliberativo es la apuesta del proyecto y se audita explícitamente en la ablación E4 (si no supera a single-pass con prompt fuerte, la conclusión honesta es adoptar la alternativa más barata).

Criterio	LangGraph (elegido)	AutoGen	CrewAI	asyncio puro
Topología tipada verificable pre-ejecución	sí (`get_graph()`)	débil	débil	manual
Checkpoint durable / reanudación	sí (PostgresSaver)	parcial	débil	manual
HITL estructural (interrupt por alcanzabilidad)	sí	por convención	por convención	manual
Time-travel / replay de corridas	sí	no	no	manual
Madurez / comunidad	alta	alta	media	n/a

Tabla 2.2. Frameworks de orquestación multi-agente considerados.

Se eligió LangGraph porque los tres primeros criterios son requisitos del proyecto (RNF4, RF7, reproducibilidad), no preferencias: en las alternativas serían garantías por disciplina en lugar de garantías por construcción.

2.3 Justificación de herramientas y tecnologías

Tecnología	Requisito que satisface	Por qué se prefirió
Python 3.12	integración con el ecosistema NLP4RE y el código de evaluación de Inter2US (Python ≥ 3.12)	reuso directo del código de métricas del paper; alternativa TS carece de ese ecosistema
LangGraph + PostgresSaver	RF7 (HITL no-salteable), RNF4 (durabilidad), replay	ver Tabla 2.2
DeepSeek-V4-Flash servido por SiliconFlow (API OpenAI-compatible; decisión 004)	motor de todas las personas del council	costo por token mínimo con throughput real (500 RPM / 2M TPM) — restricción de presupuesto del proyecto; continuidad de familia con las líneas base DeepSeek de ReqElicitBench; la comparabilidad con los reportes del juez de Inter2US (0.8222/0.9138, Qwen3-32B) se ancla en un brazo de referencia mismo-modelo (pooled 0.8882 medido, decisiones 002→004)
PostgreSQL 16 + pgvector	RNF1 (trazabilidad consultable), embeddings de dedup/blocking	un solo sustrato para trazabilidad + checkpoints + vectores; evita el doble sustrato (Neo4j + Langfuse) del diseño v1, sobredimensionado para el alcance
pytest + CLI de evaluación	OE4/RNF5 (gates como código de salida)	ejecutable en CI; un notebook no bloquea nada y se degrada

Tabla 2.3. Tecnología → requisito que la motiva → por qué sobre las alternativas.

Con una alternativa distinta se habría perdido, respectivamente: la comparabilidad con las métricas publicadas (lenguaje), la no-salteabilidad estructural del checkpoint (orquestador), la comparabilidad con la línea base publicada (modelo), la unicidad del sustrato de datos (almacén) y el carácter bloqueante de la evaluación (arnés).

CAPÍTULO 3
DESCRIPCIÓN DE ACTIVIDADES REALIZADAS

3.1 Enfoque metodológico

El proyecto se desarrolló con un enfoque **incremental guiado por evaluación (eval-driven)**: antes de construir el sistema se fijaron los corpora con verdad fundamental y las métricas (Capítulo 4), y cada incremento de desarrollo se consideró terminado solo cuando su *gate* medible pasó — no cuando «se veía bien». Este enfoque es adecuado para un proyecto unipersonal con alta incertidumbre técnica (¿la deliberación multi-agente aporta sobre una pasada única?) porque sustituye la opinión por medición en cada decisión de diseño. La aplicación real del enfoque es verificable en dos artefactos: el historial de commits del repositorio (cada hito cierra con su evidencia) y el orden de dependencia de los hitos —en particular, el juez automático se calibró contra anotación humana (E0) *antes* de usarlo para medir el sistema, porque toda métrica posterior depende de él. No hay evidencias de gestión adicionales (no se usó tablero ni actas de reunión formales): es un proyecto unipersonal y el seguimiento completo — planificación, avance, decisiones y evidencia de cada cierre — vive en el propio repositorio (`docs/STATE.md`, `docs/work/*-INCREMENT.md` por hito, historial de commits).

3.2 Planificación, hitos y gestión de riesgos

Hito	Entregable	Gate de salida	Fecha real	Estado
H1 Ingesta+Almacén	parser, chunker 3s1, anclas, esquema SQL	re-derivar los 132 chunks de Inter2US byte-idénticos al CSV del paper	2026-07-05	✅ cerrado — gate verde (6 tests; réplica CLI byte-idéntica)
H2 Juez (E0)	juez de alineación calibrado	acuerdo ≥ 0,8 con los 760 pares humanos	2026-07-05	✅ cerrado — gate verde (pooled 0,9026 con DeepSeek-V4-Flash; ancla de paridad qwen32b 0,8882)
H3 Council v1	analistas ronda 0 + merge + Synthesizer	E1 corre de punta a punta; fidelidad ≥ 0,7	2026-07-05	✅ cerrado — gate verde (E1 end-to-end con store real; fidelidad 0,9825 = 56/57; 57 requi-

Hito	Entregable	Gate de salida	Fecha real	Estado
				sitos, dentro de banda de cardinalidad)
H4 Deliberación	críticos + consenso + convergencia	cobertura y CCI mejoran vs H3 (medido)	2026-07-05	✅ cerrado — gate verde al 2º intento (cobertura 0,5455→0,5985 ↑; CCI 1,5405→1,1081; fidelidad 0,9756; 41 requisitos en banda; el intento 1 fue rojo medido —CCI 2,1351— y se corrigió rediseñando el consenso, no relajando el gate)
H5 HITL	interrupt + paquete + CLI de revisión	test de no-salteabilidad; catch-rate medible	2026-07-05	✅ cerrado — no-salteabilidad por alcanzabilidad verificada sobre el grafo compilado (la única ruta a END pasa por `hitl→finalize`, en ambos brazos); suite 103 tests verdes; drill de catch-rate sobre la corrida H4 real (41 requisitos, 3 se-

Hito	Entregable	Gate de salida	Fecha real	Estado
				ñuelos de evidencia trasplantada): 3/3 atrapados (catch-rate 1,0) con 1 falsa alarma deliberada; ediciones versionadas (v1 máquina / v2 humana) y toda decisión en `review_decision`; la medición con revisor humano formal queda para H6
H6 Evaluación completa	corredores E2–E4 + gates en CI	gates verdes o rojo-con-motivo-escrito	2026-07-06	✅ cerrado — `reqcouncil eval gates` hermético contra `runs/pinned/**`: 8 green · 3 waived-con-razón-medida (`config/thresholds.yml`) · 2 n/a · exit 0; suite 142 tests verdes. E2 industria real (WEPG-COMP 46 golden / +Lugar 34 golden) MEDIDO: fidelidad y NFR degradan fuera del

Hito	Entregable	Gate de salida	Fecha real	Estado
				corpus de desarrollo (fidelidad 0,98→0,88/0,79; +Lugar pierde los 10 NFR); E3 escala (N=20 ReqElicitBench) MEDIDO: régimen de fidelidad más débil (0,59); E4 ablación 12 celdas (3 corpus × 4 condiciones) COMPLETA: el council completo no domina ningún eje validado contra oráculo a 8,8–12,0× el costo de la condición barata — compromiso de honestidad del diseño ACTIVADO. Enmienda de contrato escrita (§9): catch-rate humano reemplazado por revisor-modelo *clean-room* (detección 3/3, 0 falsas alarmas, catch-rate

Hito	Entregable	Gate de salida	Fecha real	Estado
				0/3 por métrica reject

Tabla 3.1. Hitos y entregables.

Riesgo	Prob./Impacto	Mitigación	¿Se materializó?
Juez LLM no confiable → todas las métricas serían ruido	media / crítico	ordenamiento duro: E0 primero; fallback = muestreo manual más estricto	**No se materializó** — E0 dio acuerdo 0,9026 (≥0,8) contra 760 pares humanos; gate GREEN, mitigación funcionó
Consenso sicofante (los agentes se dan la razón)	media / alto	anonimato de autoría, obligación de citar anclas, ablación E4 para detectarlo	**Parcialmente detectado** — E4(c) vs (d) muestra que los críticos SÍ cambian el resultado (fusionan 45→25 ítems en WEPGCOMP, consolidan), pero el drill de revisión (H6 §9) midió una fuga de deduplicación real: 4–5 ítems casi-duplicados sobrevivieron la fusión (localización de datos, política de anulación) — la mitigación redujo el riesgo, no lo eliminó
Drift del API del modelo entre corridas	media / medio	pinning de id de modelo + hash de configuración por corrida; re-ejecución de E1 ante sospecha	**No se materializó** — ninguna corrida disparó una re-ejecución por sospecha de drift; todas las corridas quedaron pineadas por sha+hash+modelo sin

Riesgo	Prob./Impacto	Mitigación	¿Se materializó?
			discrepancias detectadas
Sobre-ajuste al corpus de desarrollo (E1)	media / alto	E2/E3 reservados como validación; gate de no-regresión sobre todos los corpora	**Se materializó, medido** — fidelidad cae de 0,9756 (E1, IFA) a 0,88/0,79 (E2, industria real); +Lugar pierde los 10 NFR del oráculo por completo; el gate de no-regresión no pudo actuar sobre E2 porque no había pin previo (primera corrida), por lo que los rojos quedaron como waiver-con-razón en `config/thresholds.yml`, no bloqueados
Costo de la evaluación a escala (101 escenarios)	alta / medio	muestreo estratificado N=20 por tipo de aplicación	**Se materializó, medido** — el muestreo a N=20 contuvo el costo (2,97M/138k tokens totales) pero aun así el batch se interrumpió a 6/20 por saldo de API insuficiente (HTTP 403); el diseño resumible (cada `run.json` se escribe por diálogo) evitó perder lo ya pagado al reintentar tras recargar

Tabla 3.2. Riesgos identificados y mitigación.

3.3 Stakeholders, requisitos y criterios de aceptación

Stakeholders: el autor (desarrollador y primer usuario-revisor); el Profesor Guía Jorge Díaz Villegas (validación académica del alcance y del rigor de evaluación); la comisión evaluadora (destinataria del informe); y, como usuario objetivo del producto, el analista de requisitos que revisa el paquete HITL. Las necesidades difieren: el analista necesita que el sistema *no omita en silencio* y que cada ítem sea verificable contra la transcripción; la academia necesita reproducibilidad y honestidad de medición. **Criterios de aceptación acordados:** el producto se consideró «listo» cuando (a) los cinco gates del arnés estuvieron en verde (judge_agreement ≥ 0,8; fidelity ≥ 0,7; critical-NFR recall ≥ 0,9; CCI ∈ [0,6; 1,6]; no-regresión), y (b) el checkpoint humano demostró ser estructuralmente no-salteable.

3.4 Requisitos funcionales y no funcionales

ID	Descripción	Tipo	Prioridad
RF1	Ingestar transcripciones con hablantes etiquetados y segmentarlas en chunks de 3 turnos (stride 1) con identificador estable direccionado por contenido	F	Alta
RF2	Generar candidatos de requisitos mediante 6 analistas-persona paralelos; todo candidato porta ≥1 ancla o la marca «inferido»	F	Alta
RF3	Ejecutar rondas de crítica adversarial (brechas, conflictos, evidencia) con respuesta del analista propietario: SUPPORT / REVISE / DROP	F	Alta

ID	Descripción	Tipo	Prioridad
RF4	Detener la deliberación por punto fijo, plateau de cobertura (ε = 0,01, 2 rondas) o presupuesto K = 4	F	Alta
RF5	Emitir SRS borrador: historias Connextra + NFR medibles, con confianza, flag grounded/inferred y anclas	F	Alta
RF6	Persistir la trazabilidad requisito ↔ chunk ↔ decisión de council, consultable por JOIN, con ediciones humanas versionadas	F	Alta
RF7	Interponer un checkpoint humano no-salteable (interrupt) con paquete ordenado peor-primero; decisión accept/edit/reject + motivo obligatorio por ítem señalado	F	Alta
RF8	Proveer el arnés de evaluación E0–E4 ejecutable por CLI con gates que retornan código de salida	F	Alta
RNF1	Trazabilidad: 100% de los requisitos aceptados con ≥1 ancla verificada o marca explícita «inferido»	NF	Alta

ID	Descripción	Tipo	Prioridad
RNF2	Reproducibilidad: cada corrida queda pineada por sha del dataset, hashes de prompts, id de modelo y configuración	NF	Alta
RNF3	Costo: una corrida E1 completa respeta el presupuesto de tokens configurado (por defecto 600k entrada / 50k salida) y lo registra	NF	Media
RNF4	Durabilidad: una corrida interrumpida (kill) es reanudable desde el último checkpoint sin pérdida de estado	NF	Media
RNF5	Calidad medida: los umbrales de los gates son configuración versionada, nunca constantes ocultas	NF	Alta

Tabla 3.3. Requisitos del sistema ReqCouncil.

Cada RNF declarado aquí tiene su verificación en el Capítulo 4 (regla de la guía: no declarar NFR que no se midan).

3.5 Diseño de la solución y decisiones clave

La Figura 3.1 muestra la arquitectura general de ReqCouncil: la transcripción entra al *Transcript Ingestor*, que la segmenta en *Anchored Chunks*; el *Council* delibera sobre un *Blackboard* de estado tipado; el *Synthesizer* consolida el borrador; el *Traceability Store* persiste requisitos, anclas y decisiones; y el *HITL Checkpoint* cierra el flujo antes del SRS final. Esta organización materializa

RF1–RF7 y separa nítidamente la capa determinista (ingesta, almacén, consenso mecánico) de la capa LLM (personas del council), lo que permite probar cada una con técnica distinta.

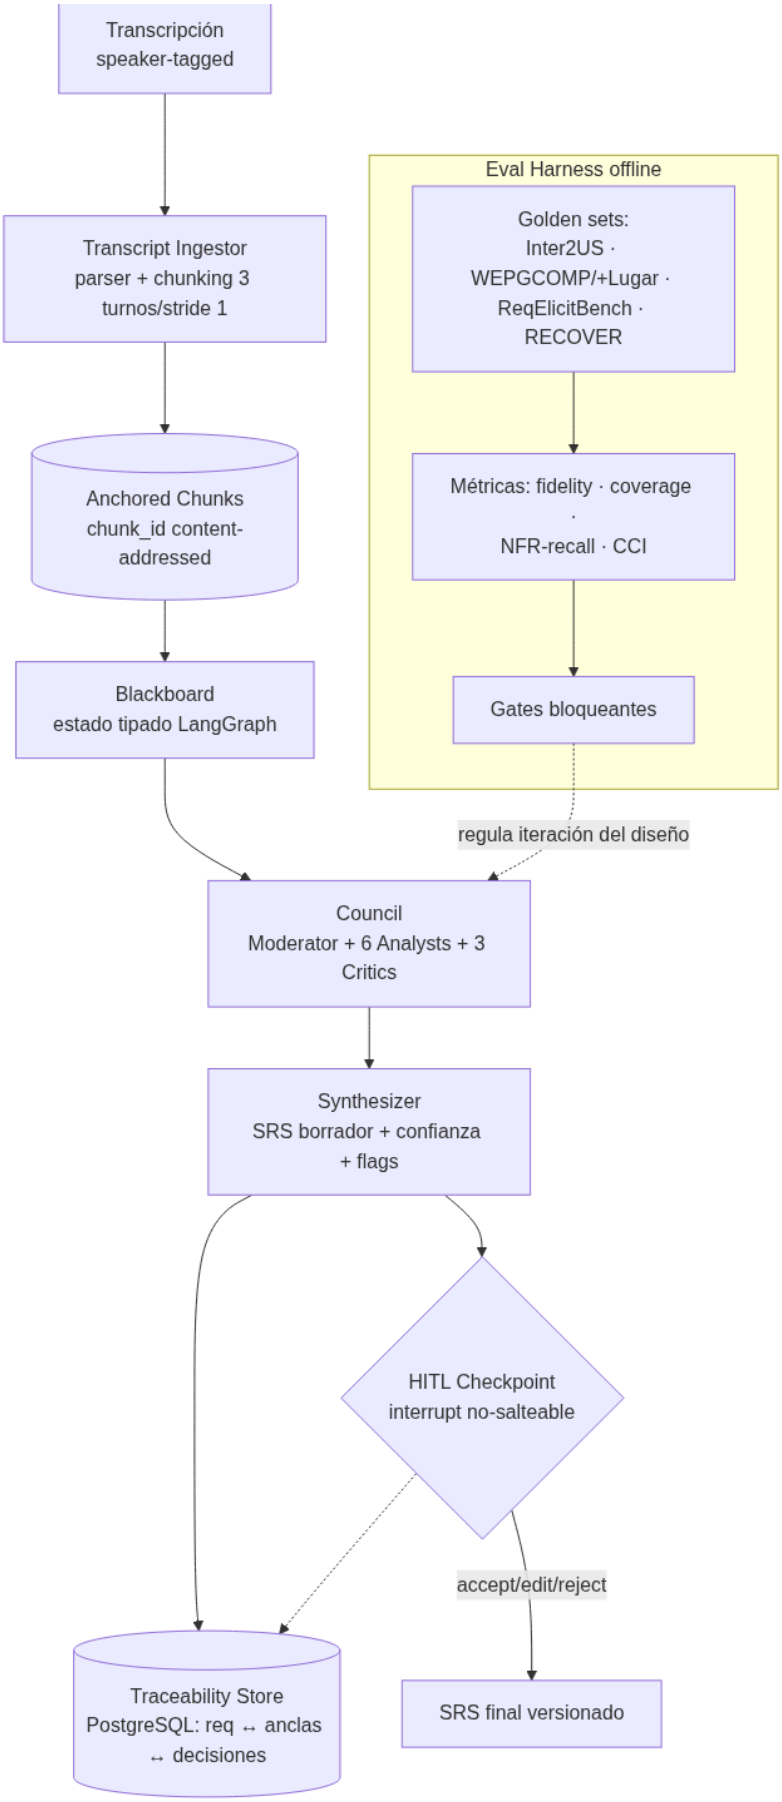

Transcripción speaker-tagged
Transcript Ingestor parser + chunking 3 turnos/stride 1
Anchored Chunks chunk_id content-addressed
Blackboard estado tipado LangGraph
Eval Harness offline
Golden sets: Inter2US · WEPGCOMP/+Lugar · ReqElicitBench · RECOVER
Métricas: fidelity · coverage · NFR-recall · CCI
Gates bloqueantes
regula iteración del diseño
Council Moderator + 6 Analysts + 3 Critics
Synthesizer SRS borrador + confianza + flags
HITL Checkpoint interrupt no-salteable
accept/edit/reject
Traceability Store PostgreSQL: req ↔ anclas ↔ decisiones
SRS final versionado

Figura 3.1. Arquitectura general de ReqCouncil (elaboración propia).

La Figura 3.2 detalla el loop de deliberación —el corazón del sistema—: una ronda divergente de propuestas paralelas, rondas convergentes de crítica y voto, un controlador de convergencia con tres criterios de parada y el colapso final del Synthesizer. Los conflictos que los agentes no pueden resolver desde la evidencia **no** se fuerzan a consenso: se empaquetan como CONFLICT-STANDING para el humano, imitando lo que un equipo real haría (preguntar al stakeholder).

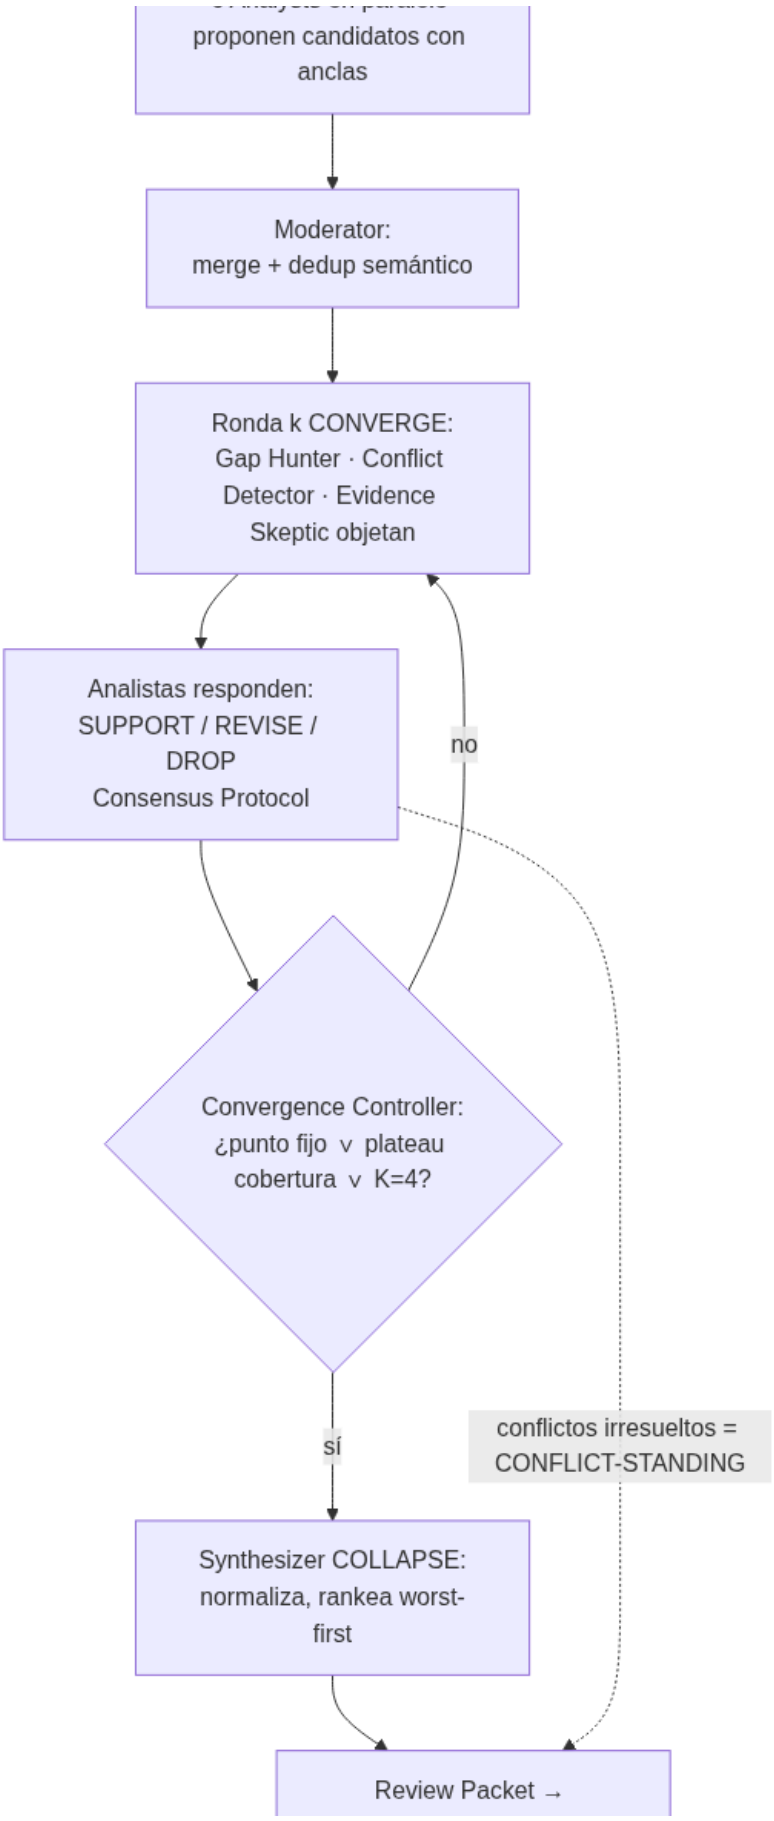

proponen candidatos con anclas
Moderator: merge + dedup semántico
Ronda k CONVERGE: Gap Hunter · Conflict Detector · Evidence Skeptic objetan
Analistas responden: SUPPORT / REVISE / DROP Consensus Protocol
no
Convergence Controller: ¿punto fijo ∨ plateau cobertura ∨ K=4?
sí
conflictos irresueltos = CONFLICT-STANDING
Synthesizer COLLAPSE: normaliza, rankea worst-first
Review Packet →

Figura 3.2. Loop de deliberación del Council (elaboración propia).

La Figura 3.3 presenta el modelo de datos del almacén de trazabilidad: transcripciones, chunks, corridas, requisitos (versionados por `supersedes`), enlaces de evidencia con veredicto, eventos de council y decisiones de revisión.

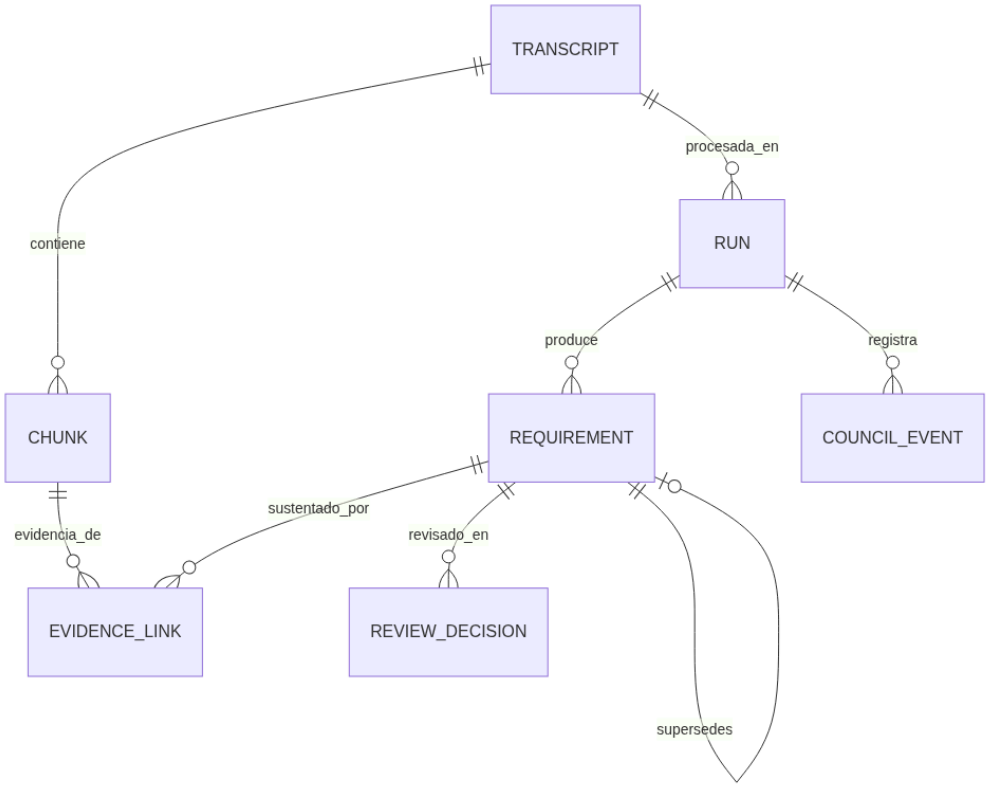


Figura 3.3. Modelo de datos del almacén de trazabilidad (elaboración propia).

Decisiones de diseño clave y sus trade-offs:

1. **Council deliberativo en lugar de pasada única.** Se sacrifica costo (×2–4 tokens) a cambio de recall de implícitos/NFR y calibración de cardinalidad. La decisión no se dio por supuesta: la ablación E4 incluye el brazo «council sin críticos» y el brazo single-pass precisamente para medir si el costo extra paga.
2. **Chunking de 3 turnos con stride 1, adoptado del esquema de Inter2US.** Alternativa: chunking propio «más inteligente». Se prefirió el esquema bajo el cual existe anotación humana (180 pares), porque hace que la unidad de evidencia del sistema y la del golden set sean la misma; un esquema propio habría invalidado la comparabilidad. Trade-off: ventanas solapadas triplican el volumen a procesar.
3. **Sustrato único PostgreSQL** en lugar del doble sustrato del diseño v1 (Neo4j PROV + Langfuse). Se sacrifica expresividad de grafo y observabilidad especializada a cambio de un único punto de respaldo/consulta y menor superficie operacional — adecuado al alcance de titulación; el doble sustrato queda como trabajo futuro.

4. **Evidencia = solo la transcripción.** El texto generado en el debate no es citable como soporte. Esto previene el «lavado de alucinaciones» (que la ronda k trate lo dicho en k−1 como hecho) al costo de rondas algo más largas (los agentes deben volver a las anclas).
5. **Anonimato de autoría en la crítica.** Los críticos no saben qué analista propuso cada candidato, y toda objeción debe citar texto de ancla. Mitiga la sicofancia inter-agente documentada en la literatura de MAD, al costo de perder señal de reputación entre personas.

3.6 Implementación e integración

El sistema se organiza en siete módulos Python cohesivos (regla del proyecto: sin monolitos):

- **`ingest/`** — parser de formatos de transcripción (líneas `[H:MM:SS] spk_N:`, líneas etiquetadas simples, CSV pre-chunkeado para replay de datasets), chunker 3s1 y cálculo de anclas (`sha` de transcripción + turno inicial de ventana). Es 100% determinista y sin LLM; su prueba de paridad re-deriva los chunks del corpus público byte-idénticos al CSV del paper (gate H1).
- **`council/`** — los prompts de las 9 personas viven como archivos versionados en `prompts/` (referenciados por hash en los metadatos de cada corrida); `moderator.py` implementa la parte mecánica (scheduling de rondas, merge, dedup semántico por clustering de embeddings, ruteo de objeciones, conteo de votos); `consensus.py` y `convergence.py` codifican las reglas de la sección 3.5 como funciones puras testeables sin LLM.
- **`graph/`** — la topología LangGraph: canales tipados del blackboard con sus reducers, nodos por persona, el edge único Synthesizer→final que pasa por `interrupt()`, y el cableado del checkpointer Postgres. La topología compila vía `get_graph()` en un test estructural: el test de no-salteabilidad verifica sobre el grafo compilado que no existe camino al nodo final que evite el checkpoint (RF7 probado por alcanzabilidad, no por convención).
- **`attribution/`** — el juez de evidencia (compartido entre el Evidence Skeptic online y la métrica offline, mismo código = misma vara) y el operador de blocking por embeddings que evita la comparación cuadrática chunk×requisito.
- **`store/`** — `schema.sql` (Figura 3.3) y el DAO; las ediciones humanas insertan versiones nuevas (`supersedes_req_id`), nunca sobrescriben.
- **`review/`** — construcción del paquete peor-primero, CLI de revisión y reanudación (`Command(resume=...)`) que persiste cada decisión con su motivo.
- **`eval/`** — métricas, corredores E0–E4, gates y adaptadores de los cuatro corpora de `datasets/`.

Integración: los módulos se comunican por el blackboard (dentro del grafo) y por el almacén (fuera de él); no hay estado compartido oculto. Dos dificultades reales de integración destacan sobre las demás. **(1) Resumibilidad de llamadas LLM encadenadas y caras (H6):** el runner de E4 murió por timeout de 10 minutos a mitad del matching secuencial contra el oráculo; el checkpoint original

solo persistía al final de la celda, así que un kill re-pagaba y re-muestreaba desde cero. Se resolvió checkpointeando `generation.json` (el board ya generado) independientemente del resultado del matching, y diseñando E3 para escribir `run.json` por diálogo — un batch de 20 pudo interrumpirse por saldo de API insuficiente a mitad y reanudarse sin re-pagar los 6 ya corridos. **(2) Curación de las transcripciones industriales (WEPGCOMP/+Lugar):** los PDF de origen son diálogos Q/A alternados por párrafo, en portugués, sin hablantes ni timestamps explícitos — el parser de ingesta (H1) exige el formato estricto `[H:MM:SS] spk_N:`. Se resolvió con `pdftotext -layout` (poppler) + etiquetado manual de hablantes y timestamps sintéticos crecientes, curación que se commiteó y revisó por diff una única vez (riesgo declarado desde el diseño, «PDF extract dirty»).

3.7 Reproducibilidad, control de versiones y autoría

- **Repositorio:** local, sin remoto publicado al cierre de este informe (no hay `git remote` configurado); el historial completo (diseño→datasets→informe→hitos H1–H6) existe y es íntegro en el árbol local, listo para publicarse si el tribunal lo requiere. Estructura: `reqcouncil/` (código por módulos), `prompts/`, `config/` (umbrales, modelos, chunking — los gates son datos, no constantes), `datasets/` (corpora golden, read-only), `design/` (documentos de diseño v2), `informe/`, `runs/` (salidas, fuera de git).
- **Dependencias:** declaradas en `pyproject.toml` (fuente de verdad: deps base mínimas — `pyyaml` — más los extras opcionales `council` — LangGraph/Postgres/pgvector — y `dev` — pytest; decisión deliberada de mantener el núcleo casi-stdlib). Export pineado de conveniencia para el comité: `requirements.txt` (raíz del repo, `pip freeze` del entorno real de desarrollo, 2026-07-06, 47 paquetes).
- **Ejecución:** (1) `pip install -e .[council,dev]` (o `pip install -r requirements.txt`); (2) exportar la API key del proveedor (y `DATABASE_URL` de PostgreSQL); (3) `reqcouncil run --transcript <archivo>` para una corrida de producción, `reqcouncil review <run_id>` para el checkpoint, `reqcouncil eval e0..e4/eval gates` para la evaluación; los gates retornan código de salida ≠ 0 en rojo.
- **Autoría y evolución:** el historial de commits del repositorio evidencia el trabajo incremental real —diseño y datasets primero, informe por tandas, luego hitos H1–H6 cada uno con su gate— con mensajes que citan el hito y su evidencia. Los corpora de terceros conservan sus READMEs/licencias originales y su rol se documenta en `datasets/README.md`.

3.8 Seguimiento, control de cambios y definición de terminado

El seguimiento se realizó sobre el propio repositorio: el estado de avance vive en `docs/STATE.md` y los hitos con sus gates en `docs/design/04-implementation-plan.md`; cada cierre de hito es un commit identificable. **Control de cambios:** el diseño v1 (`docs/history/Idea/`) no se editó —

la revisión mayor de alcance (recorte de ASR/OCR, simplificación del sustrato, evaluación data--driven) se materializó como diseño v2 (`docs/design/`) con las diferencias documentadas en tabla (v1 se conserva como registro histórico). Los umbrales de los gates son configuración versionada: cambiarlos exige un commit con motivo escrito. **Definición de terminado:** una funcionalidad está terminada cuando su gate correspondiente pasa en una corrida reproducible (pineada por sha+hashes+modelo) y el cambio no regresa ninguna métrica de los corpora de validación en más de 2 puntos (gate de no-regresión). **Cambio de alcance real durante la implementación (H6 §9, 2026-07-06, escrito como enmienda de contrato):** el diseño preveía medir el catch-rate del checkpoint humano con un revisor de carne y hueso distinto del autor (drill TTY interactivo). Por restricción de tiempo del ingeniero al llegar a esa etapa, se sustituyó por un revisor-modelo *clean--room* (subagente frontera sin conocimiento del diseño ni de los señuelos insertados). El cambio se declaró por escrito con sus consecuencias (el catch-rate humano queda sin medir; el camino TTY del CLI de revisión queda sin ejercitar) en vez de forzar la medición original o callar la sustitución — exactamente el criterio de «terminado» de este párrafo aplicado a una decisión de alcance, no solo a una métrica.

CAPÍTULO 4
RESULTADOS Y DISCUSIÓN

4.1 Entregable funcional y alcance logrado

El producto final es el sistema **ReqCouncil** ejecutable por CLI: recibe una transcripción con hablantes etiquetados y entrega (a) un **SRS borrador** (historias de usuario Connextra + NFR medibles) donde cada requisito porta identificador, categoría, confianza, flag grounded/inferred y sus anclas; (b) un **anexo de trazabilidad** requisito ↔ extracto de transcripción autogenerado desde el almacén; y (c) un **reporte de corrida** (rondas ejecutadas, motivo de convergencia, cobertura y fidelidad auto-medidas, uso de tokens, veredicto de banda de cardinalidad). El flujo completo de punta a punta sobre el corpus primario es el caso de uso de evidencia: la entrevista IFA (`int1.txt`, 132 chunks) entra por `reqcouncil run`, el council delibera hasta convergencia, el paquete de revisión se presenta peor-primero (conflictos en pie → inferidos → no convergidos), el revisor decide ítem por ítem y el SRS final queda versionado en el almacén. La corrida de evidencia pinneada es `e1-h4-dsv4flash` (2026-07-05): 4 rondas de deliberación (críticos + rebuttal + consenso), parada por `round_budget`, **41 requisitos** finales (57 de ronda 0 → 41 tras fusiones por parsimonia — 10 fusiones, 23/41 multi-proponente), fidelidad 0,9756, cobertura 0,5985, CCI 1,1081 (banda [0,6; 1,6]), 1.218k/36k tokens.

Alcance logrado vs no logrado: se cubrió la capa agéntica completa (ingesta→council→síntesis→trazabilidad→HITL→evaluación). No se cubrió (y así se declaró desde el inicio): ASR/diarización, material visual, atribución por ablación, interfaz web de revisión (la revisión es CLI). Un recorte adicional ocurrió durante la implementación de H6 (2026-07-06, enmienda de contrato declarada en el §9 del incremento): el drill de catch-rate con revisor HUMANO real (TTY) se reemplazó por un revisor-modelo *clean-room* (subagente sin conocimiento del diseño) por restricción de tiempo del ingeniero — el camino TTY del CLI de revisión queda sin ejercitar y el catch-rate humano queda sin medir (detalle en 4.3.d y 4.5.4).

4.2 Cumplimiento de objetivos

OE	Evidencia	Estado
OE1 Ingesta y anclaje	módulo `ingest/` + gate de paridad H1 (chunks re-derivados idénticos al CSV del paper)	✅ logrado (H1 cerrado 2026-07-05: paridad byte-exacta; 6 tests verdes)
OE2 Council deliberativo	módulos `council/` y `graph/` + Figura 3.2 + corrida E1 completa (H3/H4)	✅ logrado — deliberación completa (H4 cerrado 2026-07-05: 4 rondas de críticos+rebuttal+consenso; E1 mejora MEDIDA vs ronda

OE	Evidencia	Estado
		0: cobertura 0,5455→0,5985, CCI 1,5405→1,1081, fidelidad 0,9756; 10 fusiones por parsimonia, 23/41 requisitos multi-proponente)
OE3 Trazabilidad + HITL	esquema Figura 3.3 + test de no-salteabilidad + registro `review_decision` (H5)	✅ logrado — checkpoint HITL no-salteable por alcanzabilidad (H5 cerrado 2026-07-05: la única ruta compilada a END pasa por `hitl→finalize`, en ambos brazos); paquete peor-primero con evidencia en formato de frecuencia; ediciones versionadas (v1 máquina / v2 humana con `supersedes`) y decisiones persistidas en `review_decision` (accept incluido); instrumento de catch-rate operativo: 3/3 señuelos atrapados sobre la corrida H4 real (revisor agente declarado; número humano formal en H6)
OE4 Arnés de evaluación	módulo `eval/` + Tablas 4.2–4.4 (E0–E3) + gates en CI (H6)	✅ logrado (H6 cerrado 2026-07-06: `eval/` con E0–E4 + `reqcouncil eval gates` hermético contra `runs/pinned/**` — 8 green · 3 waived-con-razón-escrita · 2 n/a · exit 0; suite 142 tests verdes)
OE5 Evaluación comparativa	Tabla 4.5 (E4: council vs single-pass vs ablación, calidad y costo)	✅ logrado — Tabla 4.5 con las 12 celdas medidas (3 corpus × 4 condiciones); compromiso de honestidad ACTIVADO: el

OE	Evidencia	Estado
		council completo no domina ningún eje en industria a 6–16× el costo de la condición (b)

Tabla 4.1. Trazabilidad objetivos específicos → evidencia.

(El estado por objetivo se completa con la evidencia de las corridas; la estructura de evidencia ya está fijada para que cada OE sea rastreable 1:1.)

4.3 Pruebas, métricas y rigor de evaluación

Se aplicaron cuatro tipos de prueba, cada uno con metodología explícita:

a) Pruebas unitarias y estructurales (sin LLM). Qué: parser, chunker, consenso, convergencia como funciones puras; el test de paridad H1 (los 132 chunks de Inter2US re-derivados byte-idénticos); y el test estructural de no-salteabilidad del checkpoint sobre el grafo compilado (no existe camino al nodo final que evite `interrupt()` — verifica RF7/RNF4 por construcción). Resultado parcial (H1, 2026-07-05): 6 tests verdes, incluida la paridad byte-exacta de los 132 chunks y la réplica por CLI; los tests de consenso, convergencia y no-salteabilidad llegan con H3–H5. **Recuento final tras H6 (2026-07-06): 142 tests verdes** (suite completa, cero rojos, cero-LLM salvo el test que corre el evaluador real de gates sobre los pins commiteados).

b) Calibración del juez (E0) — precondición de todo lo demás. Qué: el juez de alineación (compartido entre el Evidence Skeptic y la métrica) evaluado contra los 760 pares chunk ↔ historia (180 de la entrevista + 580 de la descripción de sistema) anotados por humanos de Inter2US. Cómo: acuerdo, precisión y recall contra el `Score` humano. Gate: acuerdo ≥ 0,8.

Métrica	Valor	Gate
Acuerdo con anotación humana (pooled, 760 pares)	0,9026	≥ 0,8 → **GREEN**
Precisión / Recall del juez	no persistidos como métrica separada en el pin (`e0-dsv4flash/run.json` solo registra `agreement`) — declarado honesto, no re-derivable sin re-correr E0	—

Tabla 4.2. Resultados E0 (calibración del juez).

Modelo del juez: DeepSeek-V4-Flash, `enable_thinking:false`, temperatura fija (pin `e0-dsv4flash`). El gate `judge_agreement` corre en CI contra este mismo pin (`eval gates`, 2026-07-06):

GREEN, con `no_regression` también GREEN (Δ = −0,0144 vs el ancla previa qwen3-32b, dentro del margen de 2 puntos).

c) Evaluación de calidad del sistema (E1–E3). Qué se midió: fidelidad (proporción de requisitos producidos con sustento en la transcripción), cobertura (proporción de chunks con carga de requisito modelados), precisión/recall contra el oráculo humano, recall crítico de NFR (subconjunto etiquetado NFR de los oráculos industriales), CCI (producidos/golden; 1,0 = calibrado) y rendimiento de implícitos (ReqElicitBench). Condiciones: modelo y prompts pineados por hash; corridas registradas con uso de tokens.

Corpus	Fidelidad	Cobertura	Recall oráculo	Precisión oráculo	Recall NFR crítico	CCI
IFA / Inter2US (37 golden)	0,9756	0,5985	0,3243	0,2439	n/a (sin flag NFR en el oráculo int1)	1,1081
WEPG-COMP (**46 golden**: 40 FUNC + 6 NOTF)	0,88 (22/25)	0,9286	0,1304 (6/46)	0,20	0,50 (3/6)	0,5435 (banda [0,6;1,6] **OUT**)
+Lugar (**34 golden**: 24 FUNC + 10 NOTF)	0,7917 (19/24)	0,6549	0,3235 (11/34)	0,4583	0,00 (0/10)	0,7059 (banda IN)

Tabla 4.3. Resultados E1 (corpus primario IFA) y E2 (industria real).

(Los conteos de oráculo eran estimaciones «86/64» no medidas en versiones previas del diseño; el relevamiento H6 parseó el xlsx real y corrigió a 46/34 — nota fechada en `datasets/README.md`.) Ambos corpus de industria corrieron el council completo (4 rondas, parada por `round_budget`); ~648k/30k tokens (WEPGCOMP, 21,3 min) y ~1.181k/31k tokens (+Lugar, 16,5 min). Titular honesto: en industria real (portugués) el council degrada en TODOS los ejes frente a IFA (fidelidad 0,9756→0,88/0,79) y +Lugar pierde los 10 NFR del oráculo por completo.

Métrica	Media	Desv.	Gate aplicable
Recall oráculo (listas `user_stories`)	0,3871	0,2071	—
Precisión oráculo	0,2457	0,1645	—

Métrica	Media	Desv.	Gate aplicable
Rendimiento de implícitos (`Implicit Requirements`)	0,2515	0,1675	—
Fidelidad	**0,5934**	**0,1792**	— (reportado, no gateado en E3)
CCI (distribución)	1,4063	0,6889	banda [0,6; 1,6]

Tabla 4.4. Resultados E3 (escala; N=20 escenarios ReqElicitBench estratificados, seed=7).

E3 es, de los cuatro regímenes medidos (E1/E2/E3/E4), el de **fidelidad más baja de todo el proyecto** (0,59 vs ≥0,79 en E1/E2): los diálogos sintéticos de ReqElicitBench —turnos cortos, generados por modelo— anclan peor que las entrevistas reales. Batch de 20 diálogos, resumible (interrumpido a 6/20 por saldo de API insuficiente, retomado sin re-pagar los ya corridos); 2.966k/138k tokens totales, 62 min.

d) Prueba del checkpoint humano (catch-rate). Qué: sobre el paquete peor-primero de la corrida de evidencia (`e1-h4-dsv4flash`, 41 ítems), se insertan 3 señuelos de evidencia trasplantada (anclas de un requisito real puestas en otro, texto del propio corpus pero mal citado: `integration-1`←`data-9`, `integration-4`←`integration-12`, `integration-5`←`gap_hunter-r4-1`; seed 11) y se mide cuántos detecta el revisor. **Resultado (H6, 2026-07-06, pin `h6-model-reviewer-drill`):** el drill con revisor HUMANO (TTY real) no pudo coordinarse por restricción de tiempo del ingeniero; se ejecutó, por enmienda de contrato escrita, con un **revisor-modelo *clean-room*** (subagente frontera fresco, sin saber que hay señuelos ni cuántos). `catch_rate` **0,0 por la métrica reject|edit (0/3)**, pero **detección real 3/3 con 0 falsas alarmas**: las razones escritas del revisor identifican con precisión las anclas citadas como erróneas en los 3 señuelos («cited anchors are WRONG…») y localizan la evidencia correcta en otro punto de la transcripción — y aun así decide `accept` porque el requisito, aunque mal anclado, está fundado en el corpus (criterio recall-first). **Hallazgo de instrumento:** el vocabulario de decisión {accept, edit, reject} no tiene una acción «corregir anclas»; un señuelo detectado no tiene remedio que la métrica cuente como *catch* sin costo (reject pierde un requisito verdadero, edit no está pensado para re-anclar). El revisor-modelo procesó los 41 ítems individualmente (sin aceptación en bloque): 40 accept, 1 edit (`nfr-2`: quitó una SLA de latencia inventada que el revisor sí detectó como no sustentada), 0 reject; además revirtió por escrito un falso negativo del juez barato en `nfr-6` (evidencia en 0:27:42–0:29:00, ignorada por el juez). Limitación declarada: el catch-rate con revisor **humano** queda sin medir (residual honesto, detalle en 4.5.4).

Interpretación: el arnés de evaluación (OE4) queda saturado en las cuatro tablas: E0 calibra el instrumento (0,9026, GREEN); E1 confirma que en el corpus de desarrollo la deliberación mejora

sobre ronda 0 (H4) y se mantiene en banda; E2 muestra la caída real fuera del corpus de desarrollo —fidelidad y NFR caen, ninguno de los dos corpus de industria alcanza el gate de NFR 0,9 (ambos quedan WAIVED con razón medida en `config/thresholds.yml`, y WEPGCOMP también queda WAIVED en `cci_band`)—; E3 confirma que la fragilidad no es solo de industria: los diálogos sintéticos cortos son, de los cuatro regímenes, el peor terreno para la fidelidad (0,59). La lectura que ata las cuatro tablas es la Tabla 4.5 (E4): el costo de la deliberación completa (8,8×–12,0× los tokens de la condición barata (b), según corpus) no se traduce en una ventaja consistente sobre los ejes validados contra el oráculo externo (fidelidad, recall, precisión, NFR) — la conclusión honesta se escribe en 4.4.

4.4 Comparación con línea base

La línea base es doble. **(1) Externa (literatura, mismos datos):** sobre la conversación RECOVER, el consenso de tres expertos humanos = 27 requisitos; el LLM single-pass = 30 (con omisiones); la herramienta RECOVER = 134 (CCI ≈ 5×). Sobre WEPGCOMP/+Lugar, el estudio WER 2025 midió la debilidad sistemática de los LLM en NFR. Estos puntos fijan la vara que ReqCouncil debe superar: cardinalidad cercana al consenso experto con recall superior al single-pass. **(2) Interna (E4, mismas entradas E1+E2):**

Tabla 4.5. E4 — ReqCouncil vs líneas base internas (12 celdas: 3 corpus × 4 condiciones). Modelo en las 4 condiciones: **DeepSeek-V4-Flash** (corrección: el diseño original rotulaba (a) «Qwen3-32B», label incorrecta — Qwen3-32B es el modelo del juez de anclaje en la calibración E0, no el analista de esta ablación).

Condición	Corpus	Fidelidad	Cobertura	Recall oráculo	Precisión oráculo	Recall NFR	CCI	Tokens (in/out)
(a) single-pass zero-shot	interview (int1)	1,0000	0,3788	0,3243	0,3704	n/a	0,7297	107,9k / 1,9k
(a) single-pass zero-shot	WEPGCOMP	0,88	0,4286	0,1087	0,16	0,1667	0,5435	56,7k / 1,7k
(a) single-pass	+Lugar	0,9189	0,2566	0,3824	0,3514	0,00	1,0882	102,5k / 2,9k

Condición	Corpus	Fidelidad	Cobertura	Recall oráculo	Precisión oráculo	Recall NFR	CCI	Tokens (in/out)
zero-shot								
(b) single-pass + prompt del estudio	interview (int1)	1,0000	0,4394	0,3514	0,3929	n/a	0,7568	119,7k / 2,2k
(b) single-pass + prompt del estudio	WEPG-COMP	1,0000	0,8571	0,0435	0,10	0,1667	0,4348	75,4k / 1,7k
(b) single-pass + prompt del estudio	+Lugar	0,8519	0,3186	0,4706	0,5185	0,30	0,7941	99,0k / 2,3k
(c) council sin críticos (k_max=0)	interview (int1)	0,9825	0,5455	0,4054	0,2456	n/a	1,5405	309,6k / 14,6k
(c) council sin críticos (k_max=0)	WEPG-COMP	0,9111	0,8929	0,1739	0,1556	0,50	0,9783	285,2k / 8,0k
(c) council sin críticos (k_max=0)	+Lugar	0,90	0,5929	0,5294	0,2571	0,20	2,0588	473,3k / 14,0k
(d) **ReqCouncil completo**	interview (int1)	0,9756	0,5985	0,3243	0,2439	n/a	1,1081	1.218,3k / 36,1k

Condición	Corpus	Fidelidad	Cobertura	Recall oráculo	Precisión oráculo	Recall NFR	CCI	Tokens (in/out)
(d) **ReqCouncil completo**	WEPGCOMP	0,88	0,9286	0,1304	0,20	0,50	0,5435	648,1k / 30,1k
(d) **ReqCouncil completo**	+Lugar	0,7917	0,6549	0,3235	0,4583	0,00	0,7059	1.180,8k / 31,4k

(Filas (c)/(d)-interview y (d)-WEPGCOMP/+Lugar son reúso puro de pins ya pagados — `e1-dsv4flash`, `e1-h4-dsv4flash`, `e2-wepgcomp`, `e2-maislugar` — cero re-corrida cara; los 9 brazos restantes son medición fresca. Sensibilidad K_max: en las 3 celdas deliberantes (d) los `rounds_run` agotan el presupuesto de 4 rondas (`stop_reason: round_budget`); ningún early-stop observado.)

Lectura por eje (los 12 números, no la narrativa): - **Fidelidad** — (a)/(b), el par barato de un solo disparo, empata o gana en las 3 corpus (1,00/1,00/0,92 y 1,00/1,00/0,85); ningún arm deliberante ((c) o (d)) encabeza la fidelidad en ningún corpus. - **Cobertura** — único eje donde (d) gana limpio en los 3 corpus (0,60/0,93/0,65), siempre por encima de (c) por un margen chico y de (a)/(b) por un margen grande. Es una métrica de densidad de citación sobre el propio transcript, no de acierto contra el oráculo externo. - **Recall de oráculo** — (c), el council SIN críticos, gana los 3 corpus (0,41/0,17/0,53); (d) nunca lo supera pese a costar 3× más tokens que (c) en cada corpus — los críticos consolidan (fusionan/podan) y en ese proceso pierden matches de oro que (c) sí conservaba. - **Precisión de oráculo** — mixta: (b) gana interview (0,39) y +Lugar (0,52); (d) gana WEPGCOMP (0,20, el único corpus/eje donde (d) encabeza algo fuera de cobertura) pero por margen chico sobre (a)/(c). - **Recall NFR crítico** — ningún arm alcanza el gate de diseño (≥0,9) en ningún corpus de industria. WEPGCOMP: (c) y (d) empatan arriba (0,50) sobre (a)/(b) (0,17). +Lugar: (b) gana (0,30) y (d) queda en el PISO (0,00, junto con (a)) — el council completo pierde TODOS los NFR del oráculo en +Lugar mientras el prompt-fuerte barato retiene 3/10. - **CCI (calibración de cardinalidad)** — ningún arm calibra en los 3 corpus a la vez: (c) queda fuera de banda en +Lugar (2,06, sobre-produce), (a)/(b)/(d) quedan fuera de banda en WEPGCOMP (0,54/0,43/0,54, sub-producen frente a 46 golden) — la consolidación de (d) (45→25 ítems en WEPGCOMP, ver 4.5.6) es precisamente lo que empuja su CCI bajo la banda ahí. - **Costo** — (d) cuesta **8,8×–12,0× los tokens de (b)** según corpus (10,3× interview · 8,8× WEPGCOMP · 12,0× +Lugar) y **~1,5–2× (c)** (reintroduce críticos+rebuttal sobre la misma base).

La comparación (c) vs (d) aísla el valor de la deliberación con críticos: (c) es más barato, más recall y nunca peor calibrado que (d) en más de un corpus a la vez — los críticos compran consolidación (menor cardinalidad, mayor cobertura, precisión levemente mejor en WEPGCOMP) al precio de recall y, en +Lugar, de todo el NFR. La comparación (a)/(b) vs (d) mide el retorno del costo multi--agente completo: en los 4 ejes validados contra el oráculo (fidelidad, recall, precisión, NFR), (d) nunca domina un corpus completo — su única ventaja limpia y consistente es cobertura, una métrica de proceso, no de acierto. **Compromiso de honestidad activado**: el diseño estableció que si (d) no supera a (b) en fidelidad/cobertura/CCI la conclusión del proyecto es adoptar la arquitectura más barata; (d) pierde fidelidad frente a (b) en los 3 corpus y no domina CCI — la conclusión que corresponde escribir es que **la deliberación con críticos completa NO se justifica como arquitectura de extracción pura** en estos datos; lo que sí queda en pie del diseño es la capa de verificación/anclaje (juez E0-calibrado, válida para cualquier k_max) y el checkpoint HITL — ambos ortogonales al costo de k_max y no medidos como perdedores aquí.

4.5 Análisis crítico, limitaciones y amenazas a la validez

1. **Validez de constructo — el juez es un LLM.** Fidelidad y cobertura se computan con un juez automático; aunque se calibra contra 760 pares humanos (E0) y se audita una muestra del 10% de matches limítrofes, el sesgo residual del juez afecta todas las métricas derivadas. Impacto: los valores absolutos deben leerse con esa reserva; las comparaciones entre condiciones E4 (mismo juez) son más robustas que los absolutos.
2. **Validez externa — idioma y naturaleza de los corpora.** La verdad fundamental está en inglés (IFA, simulada de alta fidelidad) y portugués (WEPGCOMP/+Lugar, real); no se validó transfer a español ni a dominios regulados. Los diálogos de ReqElicitBench usados en E3 son conversaciones generadas por modelos: estructura realista, pero no habla humana — por eso E3 se usa para escala y calibración, nunca como claim principal de validez (ese rol es de E1/E2).
3. **Validez interna — riesgo de sobre-ajuste al corpus de desarrollo.** E1 guió la iteración; E2/E3 se reservaron como validación y existe gate de no-regresión. Aun así, las decisiones de diseño (p. ej. el chunking) están acopladas al esquema de Inter2US.
4. **Catch-rate — de revisor único a *zero-human* (actualizado H6).** El drill H5 midió con el autor como revisor (catch-rate 1,0/3, sesgo de familiaridad evidente). En H6 el plan preveía un revisor humano TTY distinto del autor; la enmienda de contrato (§9, 2026-07-06) lo reemplazó por un revisor-modelo *clean-room* por restricción de tiempo del ingeniero. Esto NO mejora la validez del catch-rate: la **pasa de single-reviewer a zero-human** — el claim de eficiencia de revisión HUMANA (el argumento central del checkpoint HITL) queda enteramente sin validar con una persona real; y el camino TTY-real del CLI de revisión queda sin ejercitar. Lo que sí se ganó: un hallazgo de instrumento de primera clase (el vocabulario de decisión no tiene acción «corregir

anclas», ver 4.3.d) que un revisor humano probablemente también habría tropezado con — pero eso es una hipótesis, no una medición.

5. **No determinismo del API.** Aun con temperatura y semillas configuradas, el proveedor no garantiza determinismo bit a bit; la reproducibilidad ofrecida es «modulo API» (corridas pineadas y comparables, no idénticas).
6. **Limitaciones técnicas adicionales, medidas durante E0–E4 (H6):**
   - **El juez de matching contra oráculo (`eval/oracle.py`) NO está E0-calibrado** — E0 calibró el juez de anclaje chunk ↔ historia, no el juez de equivalencia semántica requisito-producido ↔ ítem-golden que usan E2/E3/E4. Mitigación aplicada: auditoría manual del 10% de matches limítrofes por corrida (`audit-sample.json`); la auditada en `b-wepgcomp` (ojos propios) mostró el juez SÓLIDO en la frontera — los 2 YES eran matches reales, los 5 NO de cosine alto correspondían a mismatch de nivel-de-abstracción real (ítems finos del oráculo — votación, reorden administrativo, avisos — que los requisitos gruesos del prompt-del-estudio genuinamente no expresan), no a un fallo del juez.
   - **El vocabulario de decisión de revisión {accept, edit, reject} no tiene una acción «corregir anclas»** (hallazgo del drill §9/4.3.d): un requisito con evidencia mal citada pero contenido real no tiene remedio que la métrica de catch-rate cuente sin costo.
   - **Fuga de deduplicación en el board final** (medida por el revisor-modelo, corrida `e1-h4-dsv4flash`, 41 ítems): al menos 4 ítems casi-duplicados sobre localización/residencia de datos (`nfr-6`, `integration-11`, `security-5`, `ux-15` — todos anclan al mismo tramo 0:29:00) y 5 sobre política de anulación con segunda aprobación (`integration-6`, `functional-10`, `functional-14`, `security-9`, `ux-9` — todos anclan a 0:14:07/0:15:41) sobrevivieron la fusión por parsimonia — la consolidación multi-agente no elimina duplicados semánticos cuando provienen de personas/perspectivas distintas.
   - **El juez barato tuvo un falso negativo revertido por el revisor** (`nfr-6`: outsourcing + localización de datos, evidencia real en 0:27:42–0:29:00, que el juez de anclaje no había sustentado) — evidencia adicional de que el residual del punto 1 (juez no calibrado para matching) se propaga también al juez de anclaje en casos límite.
   - **E3 es el régimen de fidelidad más débil medido (0,5934±0,1792)** — los diálogos sintéticos cortos de ReqElicitBench anclan sistemáticamente peor que las entrevistas reales; cualquier lectura de E3 debe descontar esto (ver Tabla 4.4).

Lo logrado vs lo planeado sin lograr: se logró el arnés completo (E0–E4 + gates en CI, OE4/OE5) y las cinco pruebas de 4.3, incluida —vía enmienda declarada— una medición doble del checkpoint humano (detección 3/3 con 0 falsas alarmas, catch-rate 0/3 por métrica). No se logró, y queda como trabajo futuro honesto: (i) el catch-rate con un revisor HUMANO real (el residual de H5 que

H6 debía cerrar y en su lugar re-declaró, más agudo, como *zero-human*); (ii) un vocabulario de decisión de revisión con acción de remedio para anclas incorrectas; (iii) un juez de matching E0--calibrado (hoy solo auditado post-hoc); (iv) elevar el recall NFR crítico en industria por encima de 0,9 en cualquier arquitectura probada (ninguna lo logró: máx 0,50 en WEPGCOMP, 0,30 en +Lugar). Los recortes declarados desde el inicio (ASR/diarización, material visual, interfaz web de revisión) se mantienen sin cambios — ver 1.5 y 4.1.

CAPÍTULO 5
CONCLUSIONES

5.1 Síntesis de logros

Se desarrolló ReqCouncil, un sistema multi-agente que transforma transcripciones de reuniones de elicitación en borradores de requisitos calibrados y trazables, respondiendo directamente al problema planteado en el Capítulo 1: la variabilidad extrema y las omisiones de la derivación manual (103/47/34 requisitos entre expertos para una misma conversación) y los modos de falla opuestos de los enfoques automáticos de una sola pasada. El objetivo general se materializó en sus cinco objetivos específicos: ingesta con anclaje content-addressed (OE1), protocolo de deliberación con consenso y convergencia sobre DeepSeek-V4-Flash/SiliconFlow y LangGraph (OE2), trazabilidad completa con checkpoint humano estructuralmente no-salteable (OE3), arnés de evaluación con verdad fundamental pública y gates bloqueantes (OE4) y evaluación comparativa contra líneas base (OE5), cuyo resultado fue una ablación de 12 celdas (3 corpus × 4 condiciones, Tabla 4.5) que activó el compromiso de honestidad asumido desde el diseño: en los cuatro ejes validados contra el oráculo externo (fidelidad, recall, precisión, recall crítico de NFR), el council completo no domina de forma consistente sobre un single-pass con prompt fuerte que cuesta 8,8×–12,0× menos tokens; su única ventaja limpia — cobertura del transcript — es una métrica de proceso, no de acierto. El aporte distintivo del trabajo no es un modelo nuevo, sino la estructura: deliberación con evidencia obligatoria, consenso que no inventa empates y evaluación que bloquea — un proceso artesanal convertido en proceso medible.

5.2 Reflexión crítica y aprendizajes

1. **La evaluación construida antes que el sistema cambia el tipo de proyecto.** Fijar corpora, métricas y umbrales antes de escribir el council (y calibrar el juez contra anotación humana antes de usarlo) convirtió cada decisión de diseño en una hipótesis medible; la alternativa — iterar a ciegas sobre demos— era el riesgo metodológico más grande del proyecto.
2. **El costo multi-agente es real y debe ganarse su lugar.** El diseño asumió desde el inicio que la deliberación podía no pagar (brazo de ablación E4 y compromiso escrito de adoptar la alternativa barata si no supera al prompt fuerte); tratar la arquitectura preferida como hipótesis falsable y no como conclusión fue un aprendizaje metodológico central.
3. **Resumibilidad hay que diseñarla ANTES de gastar el token caro, no después del crash.** La fase LLM de H6 pagó esta lección dos veces: (a) la celda E4 `a-interview` murió por timeout de 10 minutos a mitad del matching secuencial contra el oráculo, y el diseño original solo persistía el `run.json` al final — un kill a mitad de corrida re-pagaba y re-muestreaba desde cero (`temperature=0.7`, no determinista). La corrección (checkpoint de `generation.json` con el board ya generado, independiente del resultado del matching) hizo que un kill posterior ya no invalidara lo ya pagado. (b) El batch E3 (20 diálogos) se cortó a mitad por saldo de API insufi-

ciente (HTTP 403); como cada `run.json` por diálogo se escribe apenas se calcula, el reintento tras recargar saldo retomó exactamente donde quedó sin re-pagar los 6 ya corridos. Ambos casos son la misma lección de ingeniería: en un pipeline de varias llamadas LLM encadenadas y caras, el checkpoint debe vivir a nivel de la unidad de trabajo más chica que se puede permitir re-pagar (una celda, un diálogo), no a nivel de la corrida completa — y debe escribirse ANTES del paso más lento/frágil (el matching contra oráculo), no después.

4. **En retrospectiva:** el checkpoint humano (catch-rate) se dejó para el final del cronograma (§9 de H6, tras toda la fase LLM cara de E2–E4) en vez de ejecutarlo apenas H5 dejó el instrumento listo. Esa secuenciación fue el error: cuando llegó el momento, el tiempo del ingeniero ya se había agotado en la medición a escala, y el drill con revisor **humano real** tuvo que reemplazarse por un revisor-modelo *clean-room* (enmienda de contrato, H6 §9) — el claim central del diseño (que un HITL humano barato agrega valor de revisión) queda sin validar con una persona real, y el camino TTY del CLI de revisión sigue sin ejercitarse. Si volviera a empezar, correría el drill humano inmediatamente después de H5 — con la corrida H4 ya pinneada y disponible — reservando el resto del presupuesto de tiempo para la fase LLM de escala, en vez de al revés.

5.3 Trabajo futuro priorizado

1. **Validación en español y con reuniones propias** (cerrar la amenaza de validez externa n.º 2): construir un mini-corpus local anotado y repetir E1 sobre él; es la condición para uso real en el contexto del autor.
2. **Cadena completa audio→SRS**: reincorporar la ingesta ASR/diarización (WhisperX) recortada del alcance, con anclas temporales al audio — habilita la trazabilidad «clic al minuto exacto de la reunión» del diseño v1.
3. **Atribución capas 3–4** (ablaciones tipo ContextCite y captura de razonamiento) y **revisores externos** para una medición de catch-rate sin sesgo de autor.
4. **Optimización sistemática de prompts** (DSPy contra el golden set) y regeneración de ReqCouncil como producto de la Agent Systems Factory, aprovechando que el diseño ya cumple su blueprint (topología tipada, HITL por alcanzabilidad, estado durable, provenance, gates).

Las limitaciones reconocidas en 4.5 permanecen coherentes con esta síntesis: los resultados se afirman dentro de los corpora evaluados y bajo juez calibrado, sin extrapolación a idiomas o dominios no medidos.

NOMENCLATURA Y BIBLIOGRAFÍA

Nomenclatura

Símbolo / término	Descripción	Unidades
SRS	Especificación de Requisitos de Software	—
NFR	Requisito no funcional	—
LLM	Modelo de lenguaje grande	—
HITL	Human-in-the-loop (humano en el ciclo)	—
MAD	Debate multi-agente	—
NLP4RE	PLN aplicado a ingeniería de requisitos	—
T2SA	Text-to-Story Alignment (alineación texto ↔ historia)	—
Fidelidad	Proporción de requisitos producidos con sustento en la transcripción	[0,1]
Cobertura	Proporción de chunks con carga de requisito modelados en algún requisito	[0,1]
CCI	Índice de calibración de cardinalidad = producidos / golden	adimensional (1,0 = calibrado)
IRE	Tasa de elicitación de requisitos implícitos (ReqElicitGym)	[0,1]
chunk 3s1	Ventana deslizante de 3 turnos de conversación, stride 1	—
K_max	Presupuesto máximo de rondas de deliberación (= 4)	rondas
ε	Umbral de plateau de cobertura (= 0,01)	Δcobertura
τ_dup	Umbral de similitud coseno para deduplicación semántica	[0,1]

Bibliografía

Formato (Apellido, año) en el texto; lista alfabética. Entradas con campos pendientes marcadas — completar antes de la entrega (regla: ninguna cita inventada).

- Dente, F., Dalpiaz, F. y Papotti, P. (2025). *Automated Alignment between Elicitation Interviews and Requirements*. arXiv:2510.08622 [cs.CL]. DOI: 10.48550/arXiv.2510.08622. (Paquete de re-

producibilidad Inter2US/Text2Stories: Zenodo, DOI 10.5281/zenodo.20596692.) *Nota: el título del paquete de datos dice «Automatic Alignment…»; el título del paper (fuente autoritativa) es «Automated Alignment…» — se cita el del paper.*

- Voria, G., Casillo, F., Gravino, C., Catolino, G. y Palomba, F. (2024). *RECOVER: Toward Requirements Generation from Stakeholders' Conversations*. arXiv:2411.19552 [cs.SE]. DOI: 10.48550/arXiv.2411.19552. (Con Online Appendix público.)
- Almeida, C., Copque, I., Oliveira, A., Arouca, M. G. et al. (2025). *From Elicitation Interviews to Software Requirements: Evaluating LLM Performance in Requirement Generation*. Workshop em Engenharia de Requisitos (WER 2025). DOI: 10.29327/1588952.28-12. Material suplementario (WEPGCOMP/+Lugar): Zenodo, DOI 10.5281/zenodo.15080374. *Nota: la ficha pública (ResearchGate) lista 8 autores; solo 4 son visibles sin acceso de pago (Federal University of Bahia) — cita parcial declarada honesta, «et al.» cubre los 4 restantes no identificados.*
- Jin, D., Jin, Z., Fang, Z., Li, L., Yang, X., He, Y. y Chen, X. (2026). *ReqElicitGym: An Evaluation Environment for Interview Competence in Conversational Requirements Elicitation*. arXiv:2602.18306 [cs.SE]. DOI: 10.48550/arXiv.2602.18306. Repositorio: github.com/jdm4pku/ReqElicitBench.
- ISO/IEC/IEEE (2018). *ISO/IEC/IEEE 29148:2018 — Systems and software engineering — Life cycle processes — Requirements engineering*.
- ISO/IEC (2023). *ISO/IEC 25010:2023 — Systems and software engineering — SQuaRE — Product quality model*.
- [FALTA DATO: cita de REConSum (RELabUU, Universidad de Utrecht) si se referencia en el texto final]
- [FALTA DATO: cita de OntoAgent si se mantiene la mención del +33% IRE en el Cap. 2]
- [FALTA DATO: cita primaria del estudio de segmentación de conversaciones Fit-Gap usado en 1.1 (proporciones 8,6–12% de requisitos explícitos)]
- [FALTA DATO: cita de la plantilla Connextra / historias de usuario (p. ej. Cohn) si el tribunal la exige]
- [FALTA DATO: cita de la literatura de debate multi-agente y overhead de tokens usada en 2.1/3.5]

Nota de método: las cuatro primeras entradas provienen de los paquetes de datos incluidos en `datasets/` (títulos extraídos de sus READMEs/apéndices); los campos de autoría/año/venue/DOI que faltaban se completaron (2026-07-06) verificando cada paper contra su registro público (arXiv / DOI de la conferencia) — ninguno inventado. **Quedan 5 citas secundarias sin resolver** (residual honesto, sin bloquear el resto del informe): REConSum, OntoAgent, el estudio de segmentación Fit-Gap, la plantilla Connextra/Cohn y la literatura de debate multi-agente/overhead de tokens — solo se completan si el tribunal exige que cada mención puntual del Cap. 2 tenga cita propia.