Memoria persistente en agentes LLM para ingeniería de software: un mapeo sistemático de 435 estudios con verificación automatizada

Catalina Lazo Locky
Departamento de Ciencias de la Computación e Informática
Universidad de La Frontera, Temuco, Chile
catalinalazolocky@gmail.com

***Resumen*—Contexto: los agentes basados en modelos de lenguaje ya operan durante días sobre repositorios reales, y su limitación dominante dejó de ser generar código para pasar a ser sostener la continuidad entre sesiones. La literatura llama «memoria» tanto al manejo de la ventana de contexto dentro de una tarea como a los mecanismos que persisten entre sesiones, lo que dificulta decidir con evidencia. Objetivo: mapear qué mecanismos de memoria persistente se proponen para agentes de ingeniería de software de larga vida, qué se ha medido sobre ellos y qué vacíos quedan. Método: mapeo sistemático sobre tres agregadores con exportación programática, rúbrica congelada tras calibración, una ronda de snowballing y extracción tipada contra el texto completo; 1.069 registros cribados, 500 estudios incluidos y 435 analizados a texto completo. La clasificación se delegó a modelos de lenguaje bajo compuertas deterministas y con una segunda lectura ciega independiente; toda cifra del artículo se re-deriva del corpus versionado en cada compilación. Resultados: el alcance dominante ya es el proyecto y el traspaso explícito entre sesiones es la norma (69,2 %), aunque casi siempre viaja contenido y no punteros ni contratos. Sólo 9,3 % de los estudios que declaran disparador de escritura lo dejan únicamente al criterio del modelo. La evidencia es sólida en ablation (82,8 %) y escasa en métricas de iteración (11,5 %) y en seguridad de la memoria (10,6 %). La memoria como documentos versionados es la faceta menos estudiada (7,8 %). Conclusión: sobre la recuperación medida la evidencia está en disputa —10 estudios miden que añadir una capa no ayuda y 12 que la similitud pura es insuficiente—, lo que indica que decidir *si* recuperar y decidir *con qué mecanismo* son decisiones distintas que la práctica suele confundir en una.**

***Index Terms*—mapeo sistemático, agentes LLM, memoria persistente, ingeniería de software, gestión de contexto, recuperación de información, evaluación de agentes**

I. Introducción

Los agentes basados en modelos de lenguaje dejaron de ser demostraciones de una sola respuesta para convertirse en procesos que operan durante días sobre un repositorio real. En ese régimen la restricción dominante ya no es generar código correcto en un intento, sino *sostener la continuidad*: cada sesión nueva empieza sin recuerdo de la anterior, y lo que el agente sabe de un proyecto es exactamente lo que alguien decidió escribir en alguna parte antes de que la ventana de contexto se cerrara. El problema de ingeniería que sigue abierto no es cuánto sabe el modelo, sino qué se persiste, cuándo se escribe, qué se vuelve a leer y cómo se sabe que lo persistido todavía es verdad.

La literatura responde a esa pregunta con una palabra sobrecargada. «Memoria» nombra a la vez el borrador intra-tarea que se descarta al terminar, el resumen que sobrevive a una compactación, el índice vectorial de conversaciones pasadas, el grafo de entidades de un proyecto y los pesos actualizados en tiempo de prueba. Bajo el mismo término conviven mecanismos con propiedades incompatibles, y las decisiones de diseño —¿índice semántico o lectura directa de archivos?, ¿escritura discrecional del modelo o disparada por un evento?— se toman sin un mapa de qué se ha medido y con qué evidencia.

Un mapeo sistemático previo del equipo abordó esta área con un corpus de veintisiete estudios anclado en depuración y reparación automática de programas. Ese anclaje quedó estrecho: el objeto de estudio se desplazó desde la tarea puntual hacia la operación continua sobre un proyecto. Este trabajo rehace el mapeo desde cero con un ancla distinta —memoria de proyecto en agentes de larga vida— y a otra escala: 1.069 registros únicos cribados, 500 estudios incluidos y 435 analizados contra su texto completo, de los cuales 92,9 % se publicaron en los últimos dos años.

El estudio hace dos aportes. El primero es el mapa: siete preguntas de investigación que cubren tipos y representación, ciclo de vida de escritura, recuperación e instrumentación, persistencia cross-sesión y multi-agente, evaluación y costo, riesgos, y práctica industrial de los proveedores de modelos. El segundo es metodológico. Un corpus de este tamaño no se lee a mano en el marco de un trabajo de titulación, y delegarlo a un modelo de lenguaje sin más introduce exactamente los riesgos que la comunidad ya documentó: números que no existen, citas que no resuelven y clasificaciones que nadie puede auditar. La respuesta que aquí se propone no es confiar en el modelo ni renunciar a él, sino *acotar cada decisión delegada con una compuerta determinista*: vocabularios cerrados que un validador rechaza, aritmética de rúbrica recomputada por máquina, una segunda lectura ciega que produce un coeficiente

de acuerdo, y un registro de afirmaciones donde cada cifra del artículo se re-deriva del corpus versionado en cada compilación. Ninguna de esas compuertas juzga la calidad de la prosa; todas hacen imposible una clase concreta de error.

Finalmente, el mapeo está *instrumentado para una decisión*. Las preguntas no se eligieron por completitud temática sino porque cada una corresponde a una decisión de diseño ya tomada y congelada en un sistema real —el prototipo MetaFactory, un agente de larga vida cuya memoria son documentos versionados—, y cada estudio analizado se clasificó según si la confirma, la extiende, es neutral o la refuta. Esa última categoría es la más valiosa y la que organiza la discusión: obliga a buscar activamente la evidencia que contradice las decisiones propias en vez de la que las acompaña.

II. Antecedentes

II-A. Agentes de larga vida en ingeniería de software

Un agente basado en un modelo de lenguaje que trabaja sobre un repositorio real no ejecuta una consulta sino un proceso: planifica, edita, ejecuta pruebas, lee resultados y reintenta, durante horas o días. Trabajos como Voyager [1] mostraron temprano que la acumulación de habilidades reutilizables cambia cualitativamente lo que un agente puede alcanzar en un entorno abierto, y Reflexion [2] que conservar una reflexión verbal sobre el intento fallido mejora el siguiente. Ambos comparten la observación de fondo: el desempeño depende menos de la capacidad puntual del modelo que de qué se conserva entre intentos.

II-B. Memoria y contexto: la distinción que este estudio sostiene

La ventana de contexto es memoria de trabajo, no memoria persistente: se llena, se compacta y se pierde al terminar la sesión. La literatura llama «memoria» a las dos cosas, y la ambigüedad tiene consecuencias prácticas porque los mecanismos que sirven a una no sirven a la otra. MemGPT [3] popularizó la analogía con la jerarquía de memoria de un sistema operativo —contexto como memoria principal, almacenamiento externo paginado bajo control del propio agente— y con ella la idea de que la gestión del contexto es un problema de diseño explícito. En el extremo opuesto del espectro, Titans [4] propone memorizar en tiempo de prueba dentro de los propios parámetros. Entre ambos polos se sitúa casi todo el corpus de este mapeo. Este estudio traza la frontera en la *persistencia*: un mecanismo cuenta como memoria si sobrevive a la tarea o a la sesión, o si se comparte entre agentes.

II-C. Tipos de memoria heredados de la ciencia cognitiva

La taxonomía habitual —memoria de trabajo, episódica, semántica y procedimental— proviene de la psicología cognitiva y llegó al área a través de arquitecturas de agentes. Su uso es útil como vocabulario descriptivo y engañoso como afirmación de equivalencia: que un sistema guarde episodios en una base vectorial no lo dota de memoria episódica en sentido cognitivo. Este trabajo la emplea en el primer sentido, como etiqueta de lo que el sistema declara almacenar, y complementa esa dimensión con el *sustrato* de representación —documentos, vectores, grafo, parámetros— que es lo que determina el costo y las propiedades de verificación.

III. Trabajos relacionados

El área acumula ya una cantidad notable de revisiones: la búsqueda de este mapeo identificó 172 estudios secundarios, que se apartaron sin clasificar y se usaron para vocabulario y como fuente de semillas. Esa abundancia hace necesario explicitar qué agrega este trabajo.

Las revisiones existentes se organizan mayoritariamente por *mecanismo*: taxonomías de tipos de memoria, de arquitecturas de recuperación o de operaciones de ciclo de vida. Son útiles como mapa conceptual y comparten tres límites para quien debe decidir. Primero, su alcance suele ser el agente conversacional o el agente general, no el agente de ingeniería de software que opera sobre un repositorio durante meses. Segundo, clasifican propuestas sin separar sistemáticamente qué está *medido* de qué está propuesto, distinción que aquí es un eje explícito de extracción. Tercero, y más importante para el uso que se le quiere dar: describen el espacio sin tomar posición, de modo que un ingeniero que debe elegir entre lectura directa de archivos e índice semántico sale de la lectura con un catálogo y sin un criterio.

Este mapeo se separa en esas tres dimensiones. Restringe la población a mecanismos persistentes o compartidos aplicables a agentes de larga vida; registra por estudio el tipo de evidencia que sostiene cada afirmación, incluida la ablation y la medición de costo; y clasifica cada trabajo según si confirma o refuta decisiones de diseño concretas y previamente congeladas, lo que obliga a buscar la evidencia contraria en lugar de la conveniente. Respecto de la iteración previa del propio equipo —veintisiete estudios anclados en depuración— este trabajo re-ancla el objeto, multiplica el corpus por más de un orden de magnitud y añade la verificación automatizada descrita en la sección IV-H.

IV. Metodología

El estudio sigue las guías de Petersen et al. y de Kitchenham y Charters para mapeos sistemáticos. El protocolo se redactó y se congeló antes de la clasificación, y se versionó junto con el corpus; los apartados siguientes describen lo que efectivamente se ejecutó, incluidas las desviaciones.

IV-A. Diseño del estudio y preguntas de investigación

La población son agentes basados en modelos de lenguaje aplicados a tareas de ingeniería de software y a la operación continua sobre un proyecto; el concepto son los mecanismos de memoria y gestión de contexto persistente; el contexto es la operación multi-sesión y multi-agente sobre repositorios reales, incluida la práctica industrial de los proveedores de modelos. De ahí las siete preguntas:

RQ1 ¿Qué tipos de memoria y qué sustratos de representación se proponen?

RQ2 ¿Qué operaciones y políticas gobiernan la escritura, admisión, consolidación, actualización y olvido, y qué las dispara?

RQ3 ¿Qué mecanismos de recuperación se usan y qué trabajos *miden* la utilidad de lo recuperado?

RQ4 ¿Cómo se persiste y comparte la memoria entre sesiones, agentes y niveles, y cómo se mantiene consistente con el estado real del repositorio?

RQ5 ¿Con qué benchmarks y métricas se evalúa el aporte de la memoria, incluido su costo, y qué evidencia causal existe?

RQ6 ¿Qué fallos de memoria están documentados y qué mitigaciones se proponen?

RQ7 ¿Qué mecanismos ofrecen y recomiendan los proveedores de modelos, y en qué convergen o divergen respecto de la literatura académica?

Cada pregunta se eligió porque corresponde a una decisión de diseño ya tomada en un sistema real, de modo que el mapa resultante es utilizable como insumo de decisión y no sólo como inventario temático.

IV-B. Estrategia de búsqueda y fuentes

La cadena mantiene la estructura de tres bloques unidos por conjunción —mecanismos de memoria, agentes basados en modelos de lenguaje, tareas de ingeniería de software— con sinónimos unidos por disyunción, y amplía cada bloque respecto de la iteración previa. Las fuentes son OpenAlex, Lens y arXiv nativo: las tres ofrecen exportación programática, condición que se impuso tras constatar que en la iteración anterior una fuente sin exportación dejó más de mil quinientos registros no procesables. El alcance temporal empieza en 2022, cuando aparece el régimen de agentes basados en modelos de lenguaje.

Dos decisiones merecen registro. Primera, la cadena se *auditó término a término contra el corpus ya cosechado*: cada término heredado de la iteración previa debía demostrar una contribución única de registros o se eliminaba, y dos se eliminaron con prueba de equivalencia. Segunda, el control de sanidad no usa el corpus previo como autoridad —eso habría hecho circular la validación— sino un conjunto de obras fundacionales validadas por la comunidad e independientes de aquel corpus, cuya recuperación total por búsqueda o snowballing se verificó.

IV-C. Criterios de selección y rúbrica

Se incluye un estudio primario cuyo aporte incluya un *mecanismo* de memoria o de gestión de contexto persistente, aplicable a agentes de desarrollo de larga vida por señal directa o por transferibilidad demostrable, publicado desde 2022 y en inglés. Se excluye el trabajo que usa la memoria como caja negra, el de dominio divergente sin mecanismo transferible, el secundario —que se aparta y se usa para vocabulario y snowballing, no se clasifica—, el que carece de texto suficiente y el registro que no es un estudio (depósitos de software, materiales suplementarios, portadas de actas, demos).

Tabla I
FLUJO DE SELECCIÓN, DE LA BÚSQUEDA AL CORPUS ANALIZADO

Etapa	**Excluidos**	**Restantes**
Búsqueda en tres agregadores, tras deduplicar	—	1.069
Cribado con rúbrica congelada	—	422
sin mecanismo (CE-1)	115	
dominio divergente (CE-2)	161	
registro no-estudio (CE-5)	123	
secundarios, apartados (CE-3)	172	
Snowballing: candidatos únicos	—	1.126
cribados con la misma rúbrica	—	977
incorporados	—	65
Corpus incluido	—	**500**
Sin texto completo accesible	65	
Analizados a texto completo	—	**435**

La rúbrica es aditiva sobre tres ejes: mecanismo de memoria ($M \in \{0,1,3\}$), transferibilidad a agentes de larga vida ($T \in \{0,1,2\}$) y evidencia empírica ($E \in \{0,1\}$), con inclusión si $M + T + E \geq 4$ y $M \geq 1$, exigiendo $M = 3$ cuando no hay señal de ingeniería de software. Dos anclas se precisaron tras una calibración bloqueante sobre una muestra de cincuenta registros: el mecanismo debe ser *persistente* entre tareas o sesiones, o *compartido* entre agentes —el manejo intra-tarea de la ventana de contexto puntúa cero—, y una demostración o una validación por ejemplos no cuenta como evidencia. Se añadió además una regla de calidad: un trabajo sin evidencia empírica publicado únicamente en un repositorio sin revisión pasa automáticamente a zona gris en lugar de entrar por aritmética.

Ortogonalmente a la decisión, cada incluido se etiqueta con un vocabulario cerrado de diez facetas que no puntúa y sirve para priorizar la lectura. El motivo de separar faceta y rúbrica es que la rúbrica es suficiente como compuerta pero ciega como lente: un trabajo sobre memoria conversacional y uno que gestiona el contexto como un repositorio versionado obtienen la misma nota.

IV-D. Proceso de selección

Un triaje determinista, con reglas legibles en el propio script, ordenó los registros en tres estratos y proporcionó denominadores; el triaje no decide, sólo ordena la revisión. Sobre él se ejecutó la clasificación completa con la rúbrica congelada. La tabla I resume el flujo.

IV-E. Snowballing y conjunto de control

El snowballing se ejecutó tras el cribado, en una sola ronda, tomando como semillas el conjunto incluido y el conjunto de control de la comunidad. La cosecha hacia atrás resultó *delgada* por una limitación de la fuente y no del método: la mayoría de las semillas son preprints muy recientes cuyas referencias aún no están parseadas en el agregador, hecho que se verificó consultando la API en lugar de suponerlo. La cosecha hacia adelante compensó. En total se evaluaron 1.126 candidatos únicos, de los cuales 977 llegaron a la rúbrica —el resto quedó fuera por reglas deterministas de alcance, duplicación o falta de metadatos— e incorporaron 65 estudios.

El conjunto de control quedó íntegramente dentro del corpus, y entró *por rúbrica*, no por autoridad: ninguna obra se incluyó por ser conocida.

IV-F. Extracción y síntesis tipada

Cada estudio incluido con texto completo produjo primero una fila de extracción con campos de vocabulario cerrado que responden directamente a RQ1–RQ6, y después un *digest* tipado que añade la síntesis: qué problema ataca, cómo funciona el mecanismo, qué números clave reporta y cómo se aplica a cada decisión de diseño bajo estudio. La separación no es cosmética. Los campos facetados no se re-derivan en la segunda fase: se arrastran idénticos desde la extracción congelada y una compuerta los liga por igualdad de conjuntos, de modo que cualquier deriva entre ambas fases es un rechazo automático. Así, la síntesis puede equivocarse en su prosa pero no puede reclasificar en silencio un estudio ya clasificado.

IV-G. Fiabilidad: doble lectura independiente

La primera pasada asignó un solo lector por registro, lo que deja la consistencia de la clasificación sin medir. Para cuantificarla se ejecutó una *segunda pasada independiente* sobre cuatro tipos de cola, con una regla que conviene explicitar porque de ella depende que el número signifique algo: el segundo lector recibe título, resumen y texto completo cuando existe, y **nunca** la decisión, la puntuación, las facetas, las notas ni el estrato de triaje que produjo el primero. La ceguera no se pide en la instrucción, se construye: el generador de lotes no emite esas columnas y una compuerta verifica su ausencia sobre los lotes ya construidos, antes de que comience la lectura. La comprobación se hace ahí a propósito, porque un veredicto contaminado no se puede descontaminar después ni se puede detectar mirándolo.

Las colas no son homogéneas y tratarlas como si lo fueran inflaría el coeficiente. Sólo dos de ellas —las muestras aleatorias pre-registradas de cada vía de búsqueda— admiten un coeficiente de acuerdo, porque son las únicas donde ambos lectores emitieron una decisión firme sobre la misma población. Las demás cumplen otra función: adjudicar los registros en que la primera pasada se abstuvo, confirmar las inclusiones que el triaje determinista había descartado —un subconjunto dirigido, no aleatorio, que por eso se reporta aparte—, juzgar la confianza de los registros marcados durante la extracción y resolver identidad en los pares casi duplicados.

Donde ambas lecturas coinciden, la decisión queda consolidada por dos lectores independientes. Donde discrepan, la fila pasa a una cola de conflictos que es la que recibe adjudicación humana. Ése es el propósito del procedimiento: no sustituir el juicio de la investigadora sino *concentrarlo* donde hay desacuerdo real, en lugar de repartirlo uniformemente sobre un corpus en el que la mayoría de las decisiones no están en duda.

IV-H. Automatización verificada

Un corpus de este tamaño no se clasifica a mano en el marco de un trabajo de titulación, y la alternativa —delegarlo a un modelo de lenguaje sin restricciones— reproduce los modos de fallo que la propia literatura de este mapeo documenta. El procedimiento adoptado distingue explícitamente tres tipos de decisión, con tres regímenes de confianza distintos:

- **Lo que decide la máquina, de forma determinista.** El triaje por estrato, la deduplicación, el muestreo del diez por ciento, la aritmética de la rúbrica, la validación de vocabularios cerrados, la ligadura entre extracción y síntesis y el cómputo de todo agregado. Nada de esto lo decide un modelo, y todo es re-ejecutable.
- **Lo que decide un modelo, bajo compuerta.** La lectura y clasificación de cada registro. El modelo trabaja por lotes acotados y produce un veredicto estructurado; una compuerta determinista verifica cobertura exacta del lote, pertenencia al vocabulario, coherencia entre la puntuación y la decisión, y presencia de una evidencia con ancla verificable. Un lote que falla se rehace entero. La compuerta no juzga si la lectura es buena: hace imposible que sea *mal formada*, que es una clase de error distinta y mucho más frecuente.
- **Lo que decide una persona.** Toda decisión de borde: la zona gris que sobrevive a la segunda lectura, los desacuerdos entre lecturas, las degradaciones y las fusiones de duplicados.

El mismo principio se aplica a la redacción de este artículo. Ninguna cifra del texto se escribió a mano: cada una es una macro definida en un registro de afirmaciones donde consta la pregunta que responde y la expresión que la deriva del corpus versionado, y una compuerta rechaza la compilación si una macro no está definida, si una afirmación quedó sin usar, si una cita no resuelve a un registro efectivamente cribado o si aparece un dígito literal dentro de las secciones de resultados. La consecuencia buscada es concreta: un número inventado no es improbable en este artículo, es imposible de compilar.

V. Resultados

Todos los resultados se computan sobre los 435 estudios analizados a texto completo. Los campos son multi-etiqueta: un estudio puede declarar varios tipos de memoria o varios mecanismos de recuperación, de modo que las columnas suman más que el total. Las proporciones se calculan siempre sobre 435.

V-A. Caracterización del corpus

El corpus es notablemente joven: 404 de los 435 estudios (92,9 %) se publicaron en los dos últimos años. Del total incluido (500), se obtuvo texto completo de 435 (87,0 %). El escaneo de integridad detectó 7 pares casi-duplicados entre los incluidos, y 32 registros resultaron ser herramientas o artefactos de software en lugar de estudios, catalogados aparte.

V-B. RQ1 · Tipos de memoria y sustratos de representación

La memoria episódica y la semántica dominan. La hibridación es frecuente pero no universal: 226 estudios (52,0 %) declaran dos o más tipos y 148 declaran uno solo, mientras

Tabla II
RQ1 · TIPOS DE MEMORIA Y SUSTRATO DE REPRESENTACIÓN (MULTI-ETIQUETA, $n = 435$)

Tipo de memoria	n	Representación	n
Episódica	240	Híbrida	159
Semántica	213	Documentos/archivos	121
Procedimental	120	Vectorial	102
De trabajo	89	Grafo	55
Multimodal	12	Parámetros	4
Paramétrica	9	(no declara)	45
(sin mecanismo)	61		

Tabla III
RQ2 · OPERACIONES DE CICLO DE VIDA Y DISPARADOR DE ESCRITURA ($n = 435$)

Operación	n	Disparador	n
Escritura	369	Evento determinista	300
Actualización	212	Discrecional del modelo	84
Consolidación	204	Presupuesto	55
Admisión	152	Checkpoint	56
Olvido	144	(no declara)	68
(no declara)	56		

que 61 no aportan mecanismo propio porque su contribución es un benchmark, un dataset o una medición. Calculada sobre el denominador honesto —los 374 estudios que sí proponen un mecanismo— la tasa de hibridación es 60,4 %.

Esa cifra merece atención porque *no replica* el resultado del mapeo previo del equipo, que sobre veintisiete estudios había reportado una hibridación superior al noventa por ciento. La diferencia es demasiado grande para atribuirla al azar y su explicación más plausible es un efecto de selección: un corpus pequeño reunido en torno a artículos de arquitectura sobrerepresenta los sistemas elaborados, mientras que un corpus que además incluye mediciones, protocolos de evaluación y propuestas de un solo mecanismo devuelve a la vista lo simple. La consecuencia es metodológica y excede a este trabajo: las prevalencias estimadas sobre corpus de decenas de estudios deben tratarse como hipótesis, no como caracterizaciones del área. El polo paramétrico, en cambio, se confirma desierto en ambas escalas.

V-C. RQ2 · Ciclo de vida de escritura y qué lo dispara

La escritura es la operación universalmente presente (369), pero el ciclo de vida completo no lo es: la actualización de una memoria existente aparece en 212, la consolidación en 204, la admisión —decidir qué merece entrar— en 152 y el olvido en 144. El hallazgo con mayor consecuencia de diseño está en el disparador. De los 367 estudios que declaran uno, 90,7 % emplean al menos un mecanismo no discrecional, y la lectura por exclusividad es aún más nítida: sólo 34 estudios (9,3 %) confían la escritura *únicamente* al criterio del modelo, mientras que 50 lo combinan con un disparo determinista. Es decir, la práctica mayoritaria no es prescindir de la discreción del modelo sino *acotarla*.

Tabla IV
RQ5 · TIPO DE EVIDENCIA Y MÉTRICAS REPORTADAS ($n = 435$)

Tipo de evidencia	n	Métrica	n
Benchmark end-to-end	392	Éxito final	370
Ablation con/sin	360	Otra	199
Medición de costo	200	Costo en tokens	170
Sólo cualitativa	65	Latencia	150
		Iteración	50
		Ninguna	17

V-D. RQ3 · Recuperación e instrumentación

Los embeddings son el mecanismo mayoritario (278), seguidos del ranking léxico o reordenamiento (205) y del recorrido de grafo (113). La lectura directa de archivos, sin índice, aparece en 74 estudios (17,0 %) —entre ellos propuestas que gestionan el contexto con las primitivas de un sistema de control de versiones [5], [6]—; 75 no declaran mecanismo. Sobre la instrumentación —el núcleo de la pregunta—, 347 estudios (79,8 %) miden de alguna forma qué se recuperó y con qué utilidad, y 88 no lo hacen. Conviene leer esa cifra con cuidado: «medir» aquí abarca desde reportar la exactitud de recuperación hasta ablations por elemento, y la sección de discusión muestra que la evidencia acumulada bajo esa etiqueta apunta en direcciones opuestas.

V-E. RQ4 · Persistencia cross-sesión y multi-agente

El alcance dominante es el proyecto (207), por delante de la sesión (153), la tarea (72) y la organización (37): el objeto de estudio se desplazó efectivamente hacia la operación continua. La memoria compartida entre agentes aparece en 97 estudios y la verificación de fidelidad o procedencia en 247. El traspaso explícito entre sesiones o agentes está definido en 301 (69,2 %) y ausente en 134; de los que lo definen, 296 traspasan contenido, 27 un contrato y 20 punteros. La forma de contrato, la más rara, aparece por ejemplo al refactorizar habilidades como pseudocódigo verificable [7]. El estado del plan de trabajo se trata como contenido de memoria en 71 estudios [8], [9], lo que confirma como fenómeno real una dimensión que el protocolo había registrado sólo como hipótesis.

V-F. RQ5 · Evaluación y costo

El corpus es empíricamente sólido en su dimensión principal: 392 estudios evalúan con un benchmark end-to-end y 360 (82,8 %) incluyen ablation con y sin memoria, que es la evidencia causal que el mapeo buscaba. Sólo 65 aportan evidencia exclusivamente cualitativa. El costo se mide en 200 estudios (46,0 %). El contraste está en el tipo de métrica: el éxito final se reporta en 370 casos y el costo en tokens en 170, pero las métricas de iteración aparecen sólo en 50 (11,5 %), como el trabajo que instrumenta el contexto codificado de un agente de desarrollo [10].

V-G. RQ6 · Riesgos y control

La fidelidad —procedencia, obsolescencia, consistencia entre almacenes— es una preocupación extendida: 240 estudios

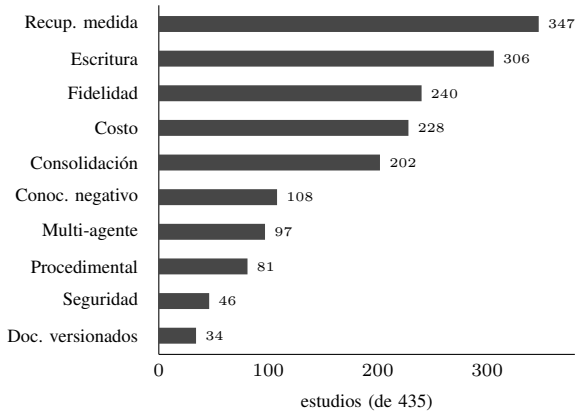


Figura 1. Prevalencia confirmada de las diez facetas contra el texto completo. Las barras se dibujan desde las mismas macros re-derivadas del corpus que usa el texto: la figura no puede discrepar de la prosa.

la tocan. La seguridad *de* la memoria, en cambio, es marginal: 46 estudios (10,6 %). Los trabajos que sí la abordan proponen validación en tiempo de evolución de la memoria [11] o flujos de admisión con revisión explícita antes de escribir [12]. Entre los modos de fallo nombrados explícitamente, la obsolescencia aparece en 69 estudios, el envenenamiento o inyección en 45 y la sobre-retención o el crecimiento sin control en 41. Un sistema que persiste conocimiento durante meses acumula exactamente esos tres riesgos, y el corpus los cubre de forma desigual.

V-H. Facetas transversales y lente de decisión

La figura 1 ordena las diez facetas por prevalencia confirmada contra el texto completo. La lectura importante es el extremo inferior, no el superior.

La síntesis produjo 1.266 mapeos entre un estudio y una decisión de diseño concreta: 551 la confirman, 489 la extienden, 160 son neutrales y 66 la refutan, estos últimos repartidos en 60 estudios distintos. Por decisión, los mapeos se concentran en la economía de contexto (257), la fidelidad (192), la recuperación medida (189) y la consolidación (169), seguidas del conocimiento negativo (117), las costuras entre almacenes (94), el estado del plan (71), el disparador de escritura (62), el índice como caché (61) y los documentos como fuente de verdad (54). La refutación se concentra en la recuperación medida (24, 36,4 % del total) y, en segundo lugar, en el conocimiento negativo (11); ambas se analizan en la sección VI.

V-I. RQ7 · Práctica industrial

La literatura gris se cosechó como corpus aparte, con semillas obligatorias fijadas en el protocolo antes de cosechar y una instantánea inmutable por documento identificada por hash: los blogs y las documentaciones mutan, de modo que la evidencia es el snapshot y no el enlace. Se analizaron 11 documentos técnicos de primera mano: 7 de Anthropic, 3 de OpenAI y 1 de Google DeepMind. Esa asimetría no es un sesgo de muestreo sino un hallazgo: la producción memoria-céntrica de Google llega por vía académica, mientras que Anthropic y OpenAI documentan mecanismo en su documentación de producto.

Los proveedores **convergen** en tratar el contexto como recurso finito administrado en tiempo de inferencia, y en separar el estado almacenado de lo que el modelo efectivamente ve. **Divergen** en dónde ponen el mecanismo: Anthropic y OpenAI ofrecen operaciones explícitas —edición de contexto y compactación del lado del servidor, herramienta de memoria y sesiones del lado del cliente— mientras que Google apuesta por capacidad bruta más caché, documentando una ventana de 1 million tokens.

Tres contrastes con la literatura académica merecen registro.

El disparador determinista está en producción, con números. La edición de contexto se activa por defecto al superar 100,000 tokens de entrada y la compactación al superar 150000; ambos son umbrales, no juicios del modelo. Al mismo tiempo, la escritura de *contenido* de memoria sí se deja al criterio del agente. Es exactamente el patrón mixto que la sección V-C midió en la literatura: la discreción del modelo no se elimina, se acota con una condición externa comprobable.

La práctica usa el sustrato que la literatura casi no estudia. La herramienta de memoria de Anthropic opera sobre archivos de texto bajo control de la aplicación, y su asistente de programación documenta la memoria de proyecto como archivos Markdown versionados junto al código. Es decir, el sustrato que aparece en 34 de 435 estudios académicos (7,8 %) es el que dos de los tres proveedores eligieron para su producto. La divergencia entre práctica y literatura, en esta faceta, es la más marcada del mapeo.

Nadie mide la utilidad de lo recuperado. Los proveedores reportan efecto agregado —una mejora de 39 % al combinar memoria con edición de contexto, una reducción de 84 % en consumo de tokens para la edición sola— pero ninguno de los 11 documentos reporta medir *qué* se recuperó y si sirvió. La carencia que la sección V-D identificó en la academia se repite, entonces, en la industria: se mide el resultado del sistema con memoria frente al sistema sin ella, no la utilidad de cada elemento recuperado. Para un agente de larga vida esa distinción no es académica, porque es la que permite decidir qué conservar.

Nota sobre estas cifras: a diferencia del resto del artículo, no son agregados sobre el corpus sino *citas*. Cada una se verifica automáticamente contra la instantánea congelada del documento que la sostiene, y si la cadena no aparece allí el artículo no compila. Es la misma disciplina aplicada a un tipo de afirmación distinto.

VI. Discusión

VI-A. El mapa de vacíos se invierte al medirlo

Antes de cribar, el protocolo estimó la prevalencia de cada faceta con expresiones regulares sobre títulos y resúmenes. Esa estimación situaba la política de escritura y el conocimiento negativo como lo más escaso de la literatura, y de ahí se derivó una hipótesis de vacío. Medida contra el texto completo de los 435 estudios, la estimación se invierte: la escritura está bien estudiada (306 estudios) y la escasez real está en

otra parte. La faceta menos representada del corpus es la memoria como *documentos versionados* —archivos, control de versiones, texto plano como sustrato [5], [13]— con 34 estudios, apenas 7,8 % del corpus; la sigue la seguridad de la memoria con 46 (10,6 %).

La lección metodológica es directa y aplica a cualquier mapeo que use pistas automáticas para priorizar: una expresión regular sobre resúmenes mide *vocabulario*, no prevalencia. La calibración lo cuantificó antes de la pasada completa —de las coincidencias sugeridas para las dos facetas más escasas, ninguna sobrevivió a la lectura— y por eso las pistas se usaron sólo para ordenar la revisión, nunca para decidirla. Un mapeo que hubiera reportado los conteos de pista como prevalencias habría publicado el vacío exactamente invertido.

VI-B. Una posición minoritaria bajo escrutinio

El sistema que motiva este mapeo tomó una decisión deliberada y documentada: recuperar leyendo archivos directamente, sin índice semántico, tras medir que el índice no se pagaba en su escala. El corpus muestra que esa es una posición minoritaria: 74 estudios (17,0 %) recuperan por lectura directa, frente a 278 que usan embeddings. La pregunta interesante no es si la posición es popular, sino qué dice la evidencia que la contradice.

De los 66 mapeos que refutan alguna decisión del sistema, 24 (36,4 % del total) apuntan a esta. Leídas una por una, no dicen lo mismo: se reparten en dos direcciones opuestas y casi empatadas. 10 miden que *añadir* una capa de recuperación no ayuda o perjudica —sistemas de memoria comerciales sin ganancia significativa sobre no tener memoria [14], un baseline de contexto largo sin memoria explícita obteniendo el mejor rango [15], [16], documentos completos en texto plano superando a recuperación vectorial y por grafo [17], un puntuador determinista sin embeddings alcanzando precisión perfecta en el primer resultado sobre documentos etiquetados [18]—. Otras 12 miden lo contrario: que la similitud *pura* es insuficiente, y que hace falta híbrido, estructura o recuperación agéntica multi-salto [19], [20], [21]. Las 2 restantes no discuten recuperación sino que el número de titular del propio trabajo contradice su tabla de resultados.

El empate no es ruido: es el hallazgo. La evidencia sobre recuperación medida está *en disputa*, y cualquier revisión que cite sólo uno de los dos bloques está seleccionando. La reconciliación razonable es que la decisión que se discute son en realidad dos, habitualmente confundidas en una: (a) si conviene tener una capa de recuperación, y (b) con qué mecanismo. Sobre (a), la evidencia favorece la abstención cuando el corpus cabe en la ventana y está curado —que es precisamente el caso de un proyecto único con documentación versionada—. Sobre (b), la evidencia es netamente desfavorable al *léxico puro*: los trabajos que comparan mecanismos sobre la misma base miden que el emparejamiento léxico es el más débil de los tres [22] y que el vector denso domina salvo en nichos de vocabulario cerrado [23], y que la similitud semántica sola falla en consultas por atributo temporal [24].

La consecuencia práctica para un sistema como el estudiado no es «agregar embeddings», sino reconocer que su decisión es defendible por el argumento (a) y no por el (b), y que su condición de validez es explícita y comprobable: que el corpus siga cabiendo en la ventana y que las consultas sigan siendo de recuperación estructurada y no de similitud abierta. El corpus también entrega el instrumento con el que esa condición se vigila —la medición de utilidad por lectura— y muestra que 347 estudios (79,8 %) ya la instrumentan de alguna forma.

VI-C. Qué debería cambiar en el diseño de agentes de larga vida

Tres asimetrías del corpus tienen consecuencia de diseño inmediata.

El disparo de escritura ya no es discrecional. Sólo 34 estudios (9,3 % de los que declaran disparador) confían la escritura únicamente al criterio del modelo; el resto la ancla en un evento determinista (300), un checkpoint (56) o un presupuesto (55), a menudo combinando ambos registros (50 estudios). «El agente escribe cuando le parece relevante», sin ninguna condición externa que lo obligue, es una práctica claramente minoritaria, y quien la conserve debería justificarla.

El traspaso entre sesiones es norma, pero viaja mal. 301 estudios (69,2 %) definen un traspaso explícito entre sesiones o agentes, de modo que la discontinuidad ya se reconoce como el problema central. Ahora bien, casi todos traspasan *contenido* (296); traspasar *punteros* (20) o un *contrato* de lo que debe cumplirse (27) sigue siendo raro. Es un espacio de diseño casi vacío, y es justamente el que evita re-copiar contexto que envejece.

El campo mide si funciona, no si deja de repetir errores. La evidencia causal es sólida: 360 estudios (82,8 %) incluyen ablation con y sin memoria. Pero las métricas de iteración —pasos, reintentos, errores repetidos, hipótesis recicladas— aparecen en 50 (11,5 %). El mapeo previo del equipo ya había señalado esta brecha con veintisiete estudios; se confirma sobre 435. Un agente de larga vida falla repitiéndose, y ésa es exactamente la dimensión que casi nadie mide.

Vale la pena registrar además dónde el corpus está desierto: sólo 4 estudios escriben la memoria en los parámetros del modelo, y 61 de los analizados no aportan mecanismo propio sino un benchmark, un dataset o una medición. Esto último es un signo de madurez incipiente: ya hay casi tantos protocolos de evaluación como sistemas que evaluar.

VII. Amenazas a la validez

VII-A. Validez de constructo

«Memoria» es un término sobrecargado y el estudio depende de dónde se trace su borde. La rúbrica exige que el mecanismo sea *persistente* —entre tareas o entre sesiones— o *compartido* entre agentes; en consecuencia, el manejo intratarea de la ventana de contexto de un solo agente queda fuera aunque sus autores lo llamen memoria. Esa frontera es defendible dado el ancla del estudio, pero es una decisión, no un hecho: un lector interesado en compresión de contexto encontrará que trabajos relevantes para él fueron excluidos

por diseño. El vocabulario de facetas es cerrado y se congeló antes de la pasada completa; una dimensión que ninguna faceta nombra es invisible para este mapa.

VII-B. Fiabilidad de la clasificación

Ésta es la amenaza principal y conviene enunciarla sin adornos. La clasificación la realizaron *modelos de lenguaje* bajo una rúbrica congelada, con compuertas deterministas que verifican la aritmética, los vocabularios y la consistencia entre fases, pero que no pueden verificar el juicio. La segunda pasada descrita en la sección IV-G es un segundo lector *modelo*, ciego a la decisión del primero: mide consistencia entre lecturas independientes, no acuerdo entre dos personas expertas. Dos lectores que comparten arquitectura pueden compartir sesgos, y ese componente de error es invisible desde dentro del propio experimento; el coeficiente reportado debe leerse como una cota de consistencia interna del procedimiento, no como validación externa. La adjudicación humana se aplicó sobre los conflictos, no sobre el corpus completo.

Aplicada al corpus, la SPI degradó 8 estudios por fallo de procedencia, fusionó 6 pares de registros que resultaron ser el mismo estudio, admitió 31 estudios que la primera pasada no había incluido y excluyó 61 que sí había incluido; el corpus post-SPI queda en 504 estudios admitidos, de los cuales 424 se analizaron a texto completo (0 elegibles aún pendientes de digerir). Sobre las muestras aleatorias pre-registradas el acuerdo colapsado fue 0,895 y el exacto 0,745; la aplicación derivó además una cola humana de 125 estudios (130 filas con ese efecto), frente a las 113 filas de desacuerdo registradas al cierre de la fase A.

VII-C. Cobertura y sesgo de accesibilidad

La búsqueda usó tres agregadores con exportación programática y quedó fuera la literatura indexada únicamente en bases con licencia. Un control de sanidad con obras validadas por la comunidad y con el corpus del mapeo previo mostró que las ausencias corresponden a un hueco de *fuente* —obras no indexadas en ninguno de los tres agregadores— y no de vocabulario, y esas obras se recuperaron por snowballing.

Más importante, y menos habitual de reportar: la pérdida de texto completo **no es aleatoria**. De los 500 incluidos se analizaron 435 (87,0 %); los 65 restantes quedaron sin PDF por protección anti-robots, ausencia de acceso abierto o páginas intermedias. De ellos, exactamente 0 son preprints: el material inaccesible proviene íntegramente de venues con DOI de editorial, mientras que 11,7 % de lo analizado son preprints. El corpus analizado está por tanto sesgado hacia lo libremente accesible, y ese sesgo apunta en la misma dirección que la señal de calidad de la próxima subsección.

La SPI añade una arista más a ese sesgo: 18 de los estudios que admitió al corpus quedaron igualmente sin texto completo para digerir, y 21 de sus exclusiones se decidieron con sólo el título a la vista.

VII-D. Calidad del corpus

El corpus es muy reciente —92,9 % de los últimos dos años— y por tanto contiene una proporción alta de preprints sin revisión por pares. La digestión marcó 85 estudios (19,5 %) con señales de calidad dudosa: venues autopublicados, evidencia sólo cualitativa presentada como medición, contradicciones entre el resumen y las tablas del propio trabajo y, en algunos casos, texto que parece generado por un asistente en lugar de resultados. La extracción, que leía campos en vez del texto completo, había marcado 35: leer el documento entero detecta más del doble de problemas. Ninguno de esos registros se descartó automáticamente —se marcaron y quedaron sujetos a revisión—, porque una señal de sospecha no es un criterio de exclusión. El lector debe saber que un corpus de esta cosecha incluye trabajo de calidad muy desigual, y ese hecho es en sí un resultado sobre el estado del área.

VII-E. Conflicto de interés analítico

La lente que clasifica cada estudio como confirmación o refutación de una decisión de diseño la aplica el mismo equipo que tomó esas decisiones. Es un riesgo evidente de complacencia. Se mitigó de tres formas comprobables: el vocabulario de posturas es cerrado y la refutación se declaró de antemano como la categoría de mayor valor; la clasificación por dirección de las refutaciones sobre la decisión más disputada vive en un archivo aparte, con la evidencia citada de cada asignación; y una compuerta exige que esa clasificación cubra *exactamente* el conjunto de refutaciones del corpus, de modo que descartar en silencio una fila incómoda hace fallar la compilación. Aun así, la mitigación es procedimental: no sustituye a una réplica independiente.

VII-F. Reproducibilidad

Protocolo, hojas de decisión, formularios, veredictos por lote y el registro de afirmaciones están versionados; cada cifra de este artículo se re-deriva de esos artefactos en cada compilación, de modo que un tercero puede recomputarlas o detectar que dejaron de seguirse del corpus. Los PDF no se distribuyen por razones de licencia: se publica su índice con identificador y hash criptográfico, que permite verificar que el documento analizado es el mismo sin redistribuirlo.

VIII. Conclusiones

Este mapeo caracterizó 435 estudios sobre memoria persistente en agentes basados en modelos de lenguaje, seleccionados de 1.069 registros mediante una rúbrica congelada y analizados contra su texto completo. Cuatro conclusiones se sostienen sobre esa base.

El objeto de estudio se desplazó y el vocabulario no lo siguió. El alcance dominante ya es el proyecto (207 estudios) y el traspaso explícito entre sesiones es norma (69,2 %), pero la literatura sigue llamando «memoria» tanto a eso como al manejo de la ventana de contexto dentro de una tarea. La distinción persistente-o-compartido frente a intra-tarea no es purismo terminológico: separa mecanismos con propiedades de verificación y costo incompatibles.

El disparo de escritura ya se resolvió, y no como suele suponerse. Sólo 34 estudios (9,3 % de los que declaran disparador) confían la escritura únicamente al criterio del modelo.

Un sistema que no ancle la escritura en alguna condición externa comprobable está adoptando la posición minoritaria y debería justificarlo.

La recuperación medida es el frente abierto, y su evidencia está en disputa. De las 66 refutaciones que el corpus opone a decisiones de diseño concretas, 36,4 % apuntan aquí, y se reparten casi por igual entre las que miden que añadir una capa de recuperación no ayuda (10) y las que miden que la similitud pura es insuficiente (12). La lectura útil no es cuál bando gana sino que la pregunta estaba mal planteada: decidir *si* recuperar y decidir *con qué mecanismo* son decisiones distintas, con condiciones de validez distintas y comprobables.

El campo mide si la memoria funciona, no si evita repetir errores. La evidencia causal es sólida (82,8 % con ablation), pero las métricas de iteración aparecen en 11,5 % de los estudios y la seguridad de la memoria en 10,6 %. Para un agente que opera durante meses, ésas son precisamente las dos dimensiones en las que fallará.

El vacío más nítido del mapa es la memoria como *documentos versionados* (34 estudios, 7,8 %): el sustrato más barato de auditar, de versionar y de verificar es el menos estudiado. Junto con el conocimiento negativo con método y las métricas de iteración, define una agenda concreta de trabajo futuro.

Como aporte metodológico, el estudio muestra que un corpus de este tamaño puede clasificarse con asistencia de modelos de lenguaje sin renunciar a la verificabilidad, siempre que cada decisión delegada esté acotada por una compuerta determinista, que se distinga explícitamente lo que decide la máquina de lo que decide un modelo y de lo que decide una persona, y que las cifras del informe se re-deriven del corpus en cada compilación en vez de copiarse. Queda como límite honesto —y como la línea de trabajo inmediata— que la verificación humana se aplicó sobre los bordes y no sobre el corpus completo, y que una réplica verdaderamente independiente exigiría revisores ajenos al equipo que tomó las decisiones bajo examen.

Referencias

[1] G. Wang, Y. Xie, Y. Jiang, A. Mandlekar, C. Xiao, Y. Zhu, L. Fan, and A. Anandkumar, "Voyager: An open-ended embodied agent with large language models," *arXiv preprint*, 2023.

[2] N. Shinn, F. Cassano, E. Berman, A. Gopinath, K. Narasimhan, and S. Yao, "Reflexion: Language agents with verbal reinforcement learning," *arXiv preprint*, 2023.

[3] C. Packer, S. Wooders, K. Lin, V. Fang, S. G. Patil, I. Stoica, and J. E. Gonzalez, "Memgpt: Towards llms as operating systems," *arXiv preprint*, 2023.

[4] A. Behrouz, P. Zhong, and V. Mirrokni, "Titans: Learning to memorize at test time," *arXiv preprint*, 2024.

[5] J. Wu, M. Hu, J. Zhu, J. Pan, Y. Liu, M. Xu, and Y. Jin, "Git context controller: Manage the context of llm-based agents like git," *arXiv preprint*, 2025.

[6] P. C. Shekar, A. H. S, and A. Krishnan, "Gitofthoughts: Version-controlled reasoning and agent memory you can replay, diff, and merge," *arXiv preprint*, 2026.

[7] X. Li, Y. Zang, Y. Cao, and A. Sun, "Skill-as-pseudocode: Refactoring skill libraries to pseudocode for llm agents," *arXiv preprint*, 2026.

[8] T. Jonsäter and A. Svensson, "Assessing continuity in agentic development across multiple development cycles," *Lund University Publications Student Papers (Lund University)*, 2026.

[9] S. K. Ravindran, "Portable agent memory: A protocol for cryptographically-verified memory transfer across heterogeneous ai agents," *arXiv preprint*, 2026.

[10] A. Vasilopoulos, "Codified context: Infrastructure for ai agents in a complex codebase," *arXiv preprint*, 2026.

[11] Y. Cheng, Y. Hu, J. Zhou, Y. Zhang, Y. Chen, H. Zhou, M. Chen, Z. Zhang, K. Shao, Y. Xie, and Z. Yin, "Tame: A trustworthy test-time evolution of agent memory with systematic benchmarking," *arXiv preprint*, 2026.

[12] X. Zhang and W. Sun, "Knowledge-based pull requests: A trusted workflow for agent-mediated knowledge collaboration," *arXiv preprint*, 2026.

[13] B. Zhang, "Beyond rag: Llm wikis as living semantic memory: Patterns, empirical findings, and open problems," *Zenodo (CERN European Organization for Nuclear Research)*, 2026.

[14] D. Deshpande, V. Gangal, H. Mehta, A. Kannappan, R. Qian, and P. Wang, "Memtrack: Evaluating long-term memory and state tracking in multi-platform dynamic agent environments," *arXiv preprint*, 2025.

[15] Y. Wang, Z. Zhang, M. Chi, K.-C. Yu, Y. Li, M. Peng, B. Tong, C. Zhang, Y. Zhou, and J. J. Li, "Evomembench: Benchmarking agent memory from a self-evolving perspective," *arXiv preprint*, 2026.

[16] Z. He *et al.*, "Memoryarena: Benchmarking agent memory in interdependent multi-session agentic tasks," *arXiv preprint*, 2026.

[17] J. R. Williams, "The markdown fallacy: Empirical evidence that format is the wrong debate for llm memory architecture," *Zenodo (CERN European Organization for Nuclear Research)*, 2026.

[18] A. Hartmann, "Temporal-stratified retrieval for ai agent memory: A structure-first alternative to vector search," *Zenodo (CERN European Organization for Nuclear Research)*, 2026.

[19] P. Rasmussen, P. Paliychuk, T. Beauvais, J. Ryan, and D. Chalef, "Zep: A temporal knowledge graph architecture for agent memory," *arXiv preprint*, 2025.

[20] Y. Shu, S. P. Jonnalagedda, X. Gao, B. J. Gutiérrez, W. Qi, K. Das, H. Sun, and Y. Su, "Remem: Reasoning with episodic memory in language agent," *arXiv preprint*, 2026.

[21] Y. S. Liu, R. Wu, L. Gallagher, J. Liang, A. Toroghi, and S. Sanner, "Semantic xpath: Structured agentic memory access for conversational ai," *arXiv preprint*, 2026.

[22] B. Yuan, Y. Su, and K. Yao, "Diagnosing retrieval vs. utilization bottlenecks in llm agent memory," *arXiv preprint*, 2026.

[23] Deng, "Entity-collision: A stratified protocol for attributing retrieval lift in agent memory," *arXiv preprint*, 2026.

[24] N. Alonso, T. Figliolia, A. Ndirango, and B. Millidge, "Toward conversational agents with context and time sensitive long-term memory," *arXiv preprint*, 2024.