Memoria persistente en agentes LLM para ingeniería de software: un mapeo sistemático de 422 estudios con verificación automatizada

Catalina Lazo Locky
Departamento de Ciencias de la Computación e Informática
Universidad de La Frontera, Temuco, Chile
catalinalazolocky@gmail.com

***Resumen*—**

***Index Terms*—mapeo sistemático, agentes LLM, memoria persistente, ingeniería de software, gestión de contexto, recuperación de información, evaluación de agentes**

I. Introducción

Los agentes basados en modelos de lenguaje dejaron de ser demostraciones de una sola respuesta para convertirse en procesos que operan durante días sobre un repositorio real. En ese régimen la restricción dominante ya no es generar código correcto en un intento, sino *sostener la continuidad*: cada sesión nueva empieza sin recuerdo de la anterior, y lo que el agente sabe de un proyecto es exactamente lo que alguien decidió escribir en alguna parte antes de que la ventana de contexto se cerrara. El problema de ingeniería que sigue abierto no es cuánto sabe el modelo, sino qué se persiste, cuándo se escribe, qué se vuelve a leer y cómo se sabe que lo persistido todavía es verdad.

La literatura responde a esa pregunta con una palabra sobrecargada. «Memoria» nombra a la vez el borrador intratarea que se descarta al terminar, el resumen que sobrevive a una compactación, el índice vectorial de conversaciones pasadas, el grafo de entidades de un proyecto y los pesos actualizados en tiempo de prueba. Bajo el mismo término conviven mecanismos con propiedades incompatibles, y las decisiones de diseño —¿índice semántico o lectura directa de archivos?, ¿escritura discrecional del modelo o disparada por un evento?— se toman sin un mapa de qué se ha medido y con qué evidencia.

Un mapeo sistemático previo del equipo abordó esta área con un corpus de veintisiete estudios anclado en depuración y reparación automática de programas. Ese anclaje quedó estrecho: el objeto de estudio se desplazó desde la tarea puntual hacia la operación continua sobre un proyecto. Este trabajo rehace el mapeo desde cero con un ancla distinta —memoria de proyecto en agentes de larga vida— y a otra escala: 1.069 registros únicos cribados, 487 estudios incluidos y 422 analizados contra su texto completo, de los cuales 93,1 % se publicaron en los últimos dos años.

El estudio hace dos aportes. El primero es el mapa: siete preguntas de investigación que cubren tipos y representación, ciclo de vida de escritura, recuperación e instrumentación, persistencia cross-sesión y multi-agente, evaluación y costo, riesgos, y práctica industrial de los proveedores de modelos. El segundo es metodológico. Un corpus de este tamaño no se lee a mano en el marco de un trabajo de titulación, y delegarlo a un modelo de lenguaje sin más introduce exactamente los riesgos que la comunidad ya documentó: números que no existen, citas que no resuelven y clasificaciones que nadie puede auditar. La respuesta que aquí se propone no es confiar en el modelo ni renunciar a él, sino *acotar cada decisión delegada con una compuerta determinista*: vocabularios cerrados que un validador rechaza, aritmética de rúbrica recomputada por máquina, una segunda lectura ciega que produce un coeficiente de acuerdo, y un registro de afirmaciones donde cada cifra del artículo se re-deriva del corpus versionado en cada compilación. Ninguna de esas compuertas juzga la calidad de la prosa; todas hacen imposible una clase concreta de error.

Finalmente, el mapeo está *instrumentado para una decisión*. Las preguntas no se eligieron por completitud temática sino porque cada una corresponde a una decisión de diseño ya tomada y congelada en un sistema real —el prototipo MetaFactory, un agente de larga vida cuya memoria son documentos versionados—, y cada estudio analizado se clasificó según si la confirma, la extiende, es neutral o la refuta. Esa última categoría es la más valiosa y la que organiza la discusión: obliga a buscar activamente la evidencia que contradice las decisiones propias en vez de la que las acompaña.

Tabla I
RQ1 · TIPOS DE MEMORIA Y SUSTRATO DE REPRESENTACIÓN (MULTI-ETIQUETA, $n = 422$)

Tipo de memoria	n	Representación	n
Episódica	229	Híbrida	159
Semántica	208	Documentos/archivos	115
Procedimental	118	Vectorial	93
De trabajo	87	Grafo	49
Multimodal	12	Parámetros	4
Paramétrica	9	(no declara)	45
(sin mecanismo)	60		

Tabla II
RQ2 · OPERACIONES DE CICLO DE VIDA Y DISPARADOR DE ESCRITURA ($n = 422$)

Operación	n	Disparador	n
Escritura	359	Evento determinista	293
Actualización	209	Discrecional del modelo	84
Consolidación	201	Presupuesto	55
Admisión	151	Checkpoint	52
Olvido	143	(no declara)	65
(no declara)	53		

II. ANTECEDENTES

II-A. Agentes LLM de larga vida en ingeniería de software

II-B. Memoria, contexto y la distinción que este estudio sostiene

II-C. Tipos de memoria heredados de la ciencia cognitiva

III. TRABAJOS RELACIONADOS

IV. METODOLOGÍA

IV-A. Diseño del estudio y preguntas de investigación

IV-B. Estrategia de búsqueda y fuentes

IV-C. Criterios de selección y rúbrica

IV-D. Proceso de selección

IV-E. Snowballing y conjunto de control

IV-F. Extracción y síntesis tipada

IV-G. Fiabilidad: doble lectura independiente

IV-H. Automatización verificada: qué decidió la máquina, qué decidió un modelo, qué decidió una persona

V. RESULTADOS

Todos los resultados se computan sobre los 422 estudios analizados a texto completo. Los campos son multi-etiqueta: un estudio puede declarar varios tipos de memoria o varios mecanismos de recuperación, de modo que las columnas suman más que el total. Las proporciones se calculan siempre sobre 422.

V-A. Caracterización del corpus

El corpus es notablemente joven: 393 de los 422 estudios (93,1 %) se publicaron en los dos últimos años. Del total incluido (487), se obtuvo texto completo de 422 (86,7 %). El escaneo de integridad detectó 7 pares casi-duplicados entre los incluidos, y 32 registros resultaron ser herramientas o artefactos de software en lugar de estudios, catalogados aparte.

V-B. RQ1 · Tipos de memoria y sustratos de representación

La memoria episódica y la semántica dominan, y la combinación es la norma: 219 estudios (51,9 %) declaran dos o más tipos, frente a 143 que declaran uno solo. El polo paramétrico —escribir la experiencia en los pesos del modelo— está prácticamente desierto, y 60 estudios no aportan mecanismo propio porque su contribución es un benchmark, un dataset o una medición.

V-C. RQ2 · Ciclo de vida de escritura y qué lo dispara

La escritura es la operación universalmente presente (359), pero el ciclo de vida completo no lo es: la actualización de una memoria existente aparece en 209, la consolidación en 201, la admisión —decidir qué merece entrar— en 151 y el olvido en 143. El hallazgo con mayor consecuencia de diseño está en el disparador: entre los estudios que declaran uno, 90,5 % usan un mecanismo no discrecional.

V-D. RQ3 · Recuperación e instrumentación

Los embeddings son el mecanismo mayoritario (267), seguidos del ranking léxico o reordenamiento (202) y del recorrido de grafo (108). La lectura directa de archivos, sin índice, aparece en 74 estudios (17,5 %); 74 no declaran mecanismo. Sobre la instrumentación —el núcleo de la pregunta—, 336 estudios (79,6 %) miden de alguna forma qué se recuperó y con qué utilidad, y 86 no lo hacen. Conviene leer esa cifra con cuidado: «medir» aquí abarca desde reportar la exactitud de recuperación hasta ablations por elemento, y la sección de discusión muestra que la evidencia acumulada bajo esa etiqueta apunta en direcciones opuestas.

V-E. RQ4 · Persistencia cross-sesión y multi-agente

El alcance dominante es el proyecto (201), por delante de la sesión (148), la tarea (70) y la organización (37): el objeto de estudio se desplazó efectivamente hacia la operación continua. La memoria compartida entre agentes aparece en 94 estudios y la verificación de fidelidad o procedencia en 244. El traspaso explícito entre sesiones o agentes está definido en 292 (69,2 %) y ausente en 130; de los que lo definen, 287 traspasan contenido, 26 un contrato y 20 punteros. El estado del plan de trabajo se trata como contenido de memoria en 70 estudios, lo que confirma como fenómeno real una dimensión que el protocolo había registrado sólo como hipótesis.

V-F. RQ5 · Evaluación y costo

El corpus es empíricamente sólido en su dimensión principal: 381 estudios evalúan con un benchmark end-to-end y 349 (82,7 %) incluyen ablation con y sin memoria, que es la evidencia causal que el mapeo buscaba. Sólo 63 aportan evidencia exclusivamente cualitativa. El costo se mide en 198 estudios (46,9 %). El contraste está en el tipo de métrica: el éxito final se reporta en 359 casos y el costo en tokens en 168, pero las métricas de iteración aparecen sólo en 50 (11,8 %).

Tabla III
RQ5 · TIPO DE EVIDENCIA Y MÉTRICAS REPORTADAS ($n = 422$)

Tipo de evidencia	n	Métrica	n
Benchmark end-to-end	381	Éxito final	359
Ablation con/sin	349	Otra	192
Medición de costo	198	Costo en tokens	168
Sólo cualitativa	63	Latencia	146
		Iteración	50
		Ninguna	17

Tabla IV
PREVALENCIA CONFIRMADA DE LAS FACETAS ($n = 422$)

Faceta	n
Recuperación medida	336
Política de escritura	296
Fidelidad y procedencia	237
Costo y presupuesto de contexto	226
Consolidación y olvido	198
Conocimiento negativo	107
Memoria compartida multi-agente	94
Memoria procedimental	79
Seguridad de la memoria	46
Documentos versionados	33

V-G. RQ6 · Riesgos y control

La fidelidad —procedencia, obsolescencia, consistencia entre almacenes— es una preocupación extendida: 237 estudios la tocan. La seguridad *de* la memoria, en cambio, es marginal: 46 estudios (10,9 %). Entre los modos de fallo nombrados explícitamente, la obsolescencia aparece en 68 estudios, el envenenamiento o inyección en 45 y la sobre-retención o el crecimiento sin control en 41. Un sistema que persiste conocimiento durante meses acumula exactamente esos tres riesgos, y el corpus los cubre de forma desigual.

V-H. Facetas transversales y lente de decisión

La tabla **??** ordena las diez facetas por prevalencia confirmada contra el texto completo. La lectura importante es el extremo inferior, no el superior.

La síntesis produjo 1.239 mapeos entre un estudio y una decisión de diseño concreta: 539 la confirman, 482 la extienden, 154 son neutrales y 64 la refutan, estos últimos repartidos en 58 estudios distintos. Por decisión, los mapeos se concentran en la economía de contexto (253), la fidelidad (188), la recuperación medida (182) y la consolidación (165), seguidas del conocimiento negativo (116), las costuras entre almacenes (91), el estado del plan (70), el disparador de escritura (61), el índice como caché (60) y los documentos como fuente de verdad (53). La refutación se concentra en la recuperación medida (23, 35,9 % del total) y, en segundo lugar, en el conocimiento negativo (10); ambas se analizan en la sección **??**.

V-I. RQ7 · Práctica industrial

VI. DISCUSIÓN

VI-A. El mapa de vacíos se invierte al medirlo

Antes de cribar, el protocolo estimó la prevalencia de cada faceta con expresiones regulares sobre títulos y resúmenes. Esa estimación situaba la política de escritura y el conocimiento negativo como lo más escaso de la literatura, y de ahí se derivó una hipótesis de vacío. Medida contra el texto completo de los 422 estudios, la estimación se invierte: la escritura está bien estudiada (296 estudios) y la escasez real está en otra parte. La faceta menos representada del corpus es la memoria como *documentos versionados* —archivos, control de versiones, texto plano como sustrato— con 33 estudios, apenas 7,8 % del corpus; la sigue la seguridad de la memoria con 46 (10,9 %).

La lección metodológica es directa y aplica a cualquier mapeo que use pistas automáticas para priorizar: una expresión regular sobre resúmenes mide *vocabulario*, no prevalencia. La calibración lo cuantificó antes de la pasada completa —de las coincidencias sugeridas para las dos facetas más escasas, ninguna sobrevivió a la lectura— y por eso las pistas se usaron sólo para ordenar la revisión, nunca para decidirla. Un mapeo que hubiera reportado los conteos de pista como prevalencias habría publicado el vacío exactamente invertido.

VI-B. Una posición minoritaria bajo escrutinio

El sistema que motiva este mapeo tomó una decisión deliberada y documentada: recuperar leyendo archivos directamente, sin índice semántico, tras medir que el índice no se pagaba en su escala. El corpus muestra que esa es una posición minoritaria: 74 estudios (17,5 %) recuperan por lectura directa, frente a 267 que usan embeddings. La pregunta interesante no es si la posición es popular, sino qué dice la evidencia que la contradice.

De los 64 mapeos que refutan alguna decisión del sistema, 23 (35,9 % del total) apuntan a esta. Leídas una por una, no dicen lo mismo: se reparten en dos direcciones opuestas y casi empatadas. 10 miden que *añadir* una capa de recuperación no ayuda o perjudica —sistemas de memoria comerciales sin ganancia significativa sobre no tener memoria, un baseline de contexto largo sin memoria explícita obteniendo el mejor rango, documentos completos en texto plano superando a recuperación vectorial y por grafo, un puntuador determinista sin embeddings alcanzando precisión perfecta en el primer resultado sobre documentos etiquetados—. Otras 11 miden lo contrario: que la similitud *pura* es insuficiente, y que hace falta híbrido, estructura o recuperación agéntica multi-salto. Las 2 restantes no discuten recuperación sino que el número de titular del propio trabajo contradice su tabla de resultados.

El empate no es ruido: es el hallazgo. La evidencia sobre recuperación medida está *en disputa*, y cualquier revisión que cite sólo uno de los dos bloques está seleccionando. La reconciliación razonable es que la decisión que se discute son en realidad dos, habitualmente confundidas en una: (a) si

conviene tener una capa de recuperación, y (b) con qué mecanismo. Sobre (a), la evidencia favorece la abstención cuando el corpus cabe en la ventana y está curado —que es precisamente el caso de un proyecto único con documentación versionada—. Sobre (b), la evidencia es netamente desfavorable al *léxico puro*: los trabajos que comparan mecanismos sobre la misma base miden que el emparejamiento léxico es el más débil de los tres y que el vector denso domina salvo en nichos de vocabulario cerrado, y que la similitud semántica sola falla en consultas por atributo temporal.

La consecuencia práctica para un sistema como el estudiado no es «agregar embeddings», sino reconocer que su decisión es defendible por el argumento (a) y no por el (b), y que su condición de validez es explícita y comprobable: que el corpus siga cabiendo en la ventana y que las consultas sigan siendo de recuperación estructurada y no de similitud abierta. El corpus también entrega el instrumento con el que esa condición se vigila —la medición de utilidad por lectura— y muestra que 336 estudios (79,6 %) ya la instrumentan de alguna forma.

VI-C. Qué debería cambiar en el diseño de agentes de larga vida

Tres asimetrías del corpus tienen consecuencia de diseño inmediata.

El disparo de escritura ya no es discrecional. Entre los estudios que declaran qué dispara la escritura, 90,5 % usan un mecanismo no discrecional: evento determinista (293), checkpoint (52) o presupuesto (55), frente a 84 que dejan la decisión al criterio del modelo. La práctica de «el agente escribe cuando le parece relevante» es minoritaria en la literatura, y quien la conserve debería justificarla.

El traspaso entre sesiones es norma, pero viaja mal. 292 estudios (69,2 %) definen un traspaso explícito entre sesiones o agentes, de modo que la discontinuidad ya se reconoce como el problema central. Ahora bien, casi todos traspasan *contenido* (287); traspasar *punteros* (20) o un *contrato* de lo que debe cumplirse (26) sigue siendo raro. Es un espacio de diseño casi vacío, y es justamente el que evita re-copiar contexto que envejece.

El campo mide si funciona, no si deja de repetir errores. La evidencia causal es sólida: 349 estudios (82,7 %) incluyen ablation con y sin memoria. Pero las métricas de iteración —pasos, reintentos, errores repetidos, hipótesis recicladas— aparecen en 50 (11,8 %). El mapeo previo del equipo ya había señalado esta brecha con veintisiete estudios; se confirma sobre 422. Un agente de larga vida falla repitiéndose, y ésa es exactamente la dimensión que casi nadie mide.

Vale la pena registrar además dónde el corpus está desierto: sólo 4 estudios escriben la memoria en los parámetros del modelo, y 60 de los analizados no aportan mecanismo propio sino un benchmark, un dataset o una medición. Esto último es un signo de madurez incipiente: ya hay casi tantos protocolos de evaluación como sistemas que evaluar.

VII. Amenazas a la validez

VII-A. Validez de constructo

«Memoria» es un término sobrecargado y el estudio depende de dónde se trace su borde. La rúbrica exige que el mecanismo sea *persistente* —entre tareas o entre sesiones— o *compartido* entre agentes; en consecuencia, el manejo intratarea de la ventana de contexto de un solo agente queda fuera aunque sus autores lo llamen memoria. Esa frontera es defendible dado el ancla del estudio, pero es una decisión, no un hecho: un lector interesado en compresión de contexto encontrará que trabajos relevantes para él fueron excluidos por diseño. El vocabulario de facetas es cerrado y se congeló antes de la pasada completa; una dimensión que ninguna faceta nombra es invisible para este mapa.

VII-B. Fiabilidad de la clasificación

Ésta es la amenaza principal y conviene enunciarla sin adornos. La clasificación la realizaron *modelos de lenguaje* bajo una rúbrica congelada, con compuertas deterministas que verifican la aritmética, los vocabularios y la consistencia entre fases, pero que no pueden verificar el juicio. La segunda pasada descrita en la sección **??** es un segundo lector *modelo*, ciego a la decisión del primero: mide consistencia entre lecturas independientes, no acuerdo entre dos personas expertas. Dos lectores que comparten arquitectura pueden compartir sesgos, y ese componente de error es invisible desde dentro del propio experimento; el coeficiente reportado debe leerse como una cota de consistencia interna del procedimiento, no como validación externa. La adjudicación humana se aplicó sobre los conflictos, no sobre el corpus completo.

VII-C. Cobertura y sesgo de accesibilidad

La búsqueda usó tres agregadores con exportación programática y quedó fuera la literatura indexada únicamente en bases con licencia. Un control de sanidad con obras validadas por la comunidad y con el corpus del mapeo previo mostró que las ausencias corresponden a un hueco de *fuente* —obras no indexadas en ninguno de los tres agregadores— y no de vocabulario, y esas obras se recuperaron por snowballing.

Más importante, y menos habitual de reportar: la pérdida de texto completo **no es aleatoria**. De los 487 incluidos se analizaron 422 (86,7 %); los 65 restantes quedaron sin PDF por protección anti-robots, ausencia de acceso abierto o páginas intermedias. De ellos, exactamente 0 son preprints: el material inaccesible proviene íntegramente de venues con DOI de editorial, mientras que 11,4 % de lo analizado son preprints. El corpus analizado está por tanto sesgado hacia lo libremente accesible, y ese sesgo apunta en la misma dirección que la señal de calidad de la próxima subsección.

VII-D. Calidad del corpus

El corpus es muy reciente —93,1 % de los últimos dos años— y por tanto contiene una proporción alta de preprints sin revisión por pares. La digestión marcó 83 estudios (19,7 %) con señales de calidad dudosa: venues autopublicados, evidencia sólo cualitativa presentada como medición,

contradicciones entre el resumen y las tablas del propio trabajo y, en algunos casos, texto que parece generado por un asistente en lugar de resultados. La extracción, que leía campos en vez del texto completo, había marcado 33: leer el documento entero detecta más del doble de problemas. Ninguno de esos registros se descartó automáticamente —se marcaron y quedaron sujetos a revisión—, porque una señal de sospecha no es un criterio de exclusión. El lector debe saber que un corpus de esta cosecha incluye trabajo de calidad muy desigual, y ese hecho es en sí un resultado sobre el estado del área.

VII-E. Conflicto de interés analítico

La lente que clasifica cada estudio como confirmación o refutación de una decisión de diseño la aplica el mismo equipo que tomó esas decisiones. Es un riesgo evidente de complacencia. Se mitigó de tres formas comprobables: el vocabulario de posturas es cerrado y la refutación se declaró de antemano como la categoría de mayor valor; la clasificación por dirección de las refutaciones sobre la decisión más disputada vive en un archivo aparte, con la evidencia citada de cada asignación; y una compuerta exige que esa clasificación cubra *exactamente* el conjunto de refutaciones del corpus, de modo que descartar en silencio una fila incómoda hace fallar la compilación. Aun así, la mitigación es procedimental: no sustituye a una réplica independiente.

VII-F. Reproducibilidad

Protocolo, hojas de decisión, formularios, veredictos por lote y el registro de afirmaciones están versionados; cada cifra de este artículo se re-deriva de esos artefactos en cada compilación, de modo que un tercero puede recomputarlas o detectar que dejaron de seguirse del corpus. Los PDF no se distribuyen por razones de licencia: se publica su índice con identificador y hash criptográfico, que permite verificar que el documento analizado es el mismo sin redistribuirlo.

VIII. Conclusiones